

# Pronóstico de series de tiempo y simulaciones en R

**Clase 5:** Series temporales multivariantes

Germán Eduardo González

# Índice

**Dependencia entre variables**

**Modelo de vectores autorregresivos (VAR)**

**Prueba de causalidad de Granger**

**Cointegración**

**Modelo de corrección de error vectoriales  
(VECM)**

**Aplicación**

# Índice

**Dependencia entre variables**

**Modelo de vectores autorregresivos (VAR)**

**Prueba de causalidad de Granger**

**Cointegración**

**Modelo de corrección de error vectoriales  
(VECM)**

**Aplicación**

# Dependencia entre variables

- La dependencia entre dos variables es cualquier relación estadística que permita pronosticar una con la otra.
- En particular, cuando el interés es pronosticar, lo que se busca son **causalidades predictivas**, diferente a lo que normalmente se entiende como **causalidad real**.
- La primera es una pregunta de ¿Qué variables X de la base datos son útiles para mejorar mi proyección de Y?, la segunda es ¿El cambio en Y es causado directamente por X?

# Índice

Dependencia entre variables

**Modelo de vectores autorregresivos (VAR)**

Prueba de causalidad de Granger

Cointegración

Modelo de corrección de error vectoriales  
(VECM)

Aplicación

# Modelo de vectores autorregresivos (VAR)

**Univariado:** En un modelo autoregresivo univariado de orden  $p$ , hacemos una regresión a la variable en  $p$  rezagos. AR (P)

$$Y_t = \beta_0 + \sum_{i=1}^p \alpha_i X_{t-i} + u_t$$

**Multivariada:** Una modelo autoregresivo multivariado es un vector autoregresivo o VAR envuelve  $N$  variables. En  $N$ -variables tenemos que estimar  $N$  diferentes ecuaciones.

En cada ecuación, estimamos las variables de la mano izquierda con  $p$  rezagos, de igual manera para las variables de la mano derecha  $p$  rezagos.

Ejemplo: VAR (1)

$$y_{1,t} = \beta_{1,0} + \beta_{1,1}y_{1,t-1} + \alpha_{1,1}y_{2,t-1} + \epsilon_{1,t}$$

$$y_{2,t} = \beta_{2,0} + \beta_{2,1}y_{2,t-1} + \alpha_{2,1}y_{1,t-1} + \epsilon_{2,t}$$

# Modelo de vectores autorregresivos (VAR)

VAR:

1. Hay **más** de una **variable dependiente**.
2. Conjunto de ecuaciones lineales dinámicas en donde cada variables es función de:
  - Un **número** igual de rezagos de si misma.
  - Todas las **otras variables** en el sistema.
3. Todas las variables son **endógenas**, es decir, son determinadas por el sistema.
4. El número de variables que queremos estimar determina el número de ecuaciones en el sistema

**Beneficios:** Incluye otro tipo de interacción multivariada. Las perturbaciones pueden estar correlacionadas, generando que un choque afecte el sistema. Estas interacciones brindan una ventaja en el pronostico que pierde el univariado.

$$y_t = \alpha_0 + \alpha_1 y_{t-1} + \epsilon_t$$

Tenemos que estimar:  $\alpha_0$  y  $\alpha_1$ .

$$y_{1,t} = \beta_{1,0} + \beta_{1,1} y_{1,t-1} + \alpha_{1,1} y_{2,t-1} + \epsilon_{1,t}$$

$$y_{2,t} = \beta_{2,0} + \beta_{2,1} y_{2,t-1} + \alpha_{2,1} y_{1,t-1} + \epsilon_{2,t}$$

Tenemos que estimar:  $\beta_{1,0}$ ,  $\beta_{1,1}$ ,  $\alpha_{1,1}$ ,  $\beta_{2,0}$ ,  $\beta_{2,1}$  y  $\alpha_{2,1}$ .

$$\epsilon_{1,t} \sim RB(0, \sigma_1^2)$$

$$\epsilon_{2,t} \sim RB(0, \sigma_2^2)$$

$$cov(\epsilon_1, \epsilon_2) = \sigma_{12}$$

# Modelo de vectores autorregresivos (VAR)

## VAR (2)

$$y_{1,t} = \beta_{1,0} + \beta_{1,1}y_{1,t-1} + \alpha_{1,1}y_{2,t-1} + \beta_{1,2}y_{1,t-2} + \alpha_{1,2}y_{2,t-2} + \epsilon_{1,t}$$

$$y_{2,t} = \beta_{2,0} + \beta_{2,1}y_{2,t-1} + \alpha_{2,1}y_{1,t-1} + \beta_{2,2}y_{2,t-2} + \alpha_{2,2}y_{1,t-2} + \epsilon_{2,t}$$

Note que:

AR(2)

Tenemos que estimar:  $\alpha_0$ ,  $\alpha_1$  y  $\alpha_2$ .

VAR(2)

Tenemos que estimar:  $\beta_{1,0}$ ,  $\beta_{1,1}$ ,  $\alpha_{1,1}$ ,  $\beta_{1,2}$ ,  $\alpha_{1,2}$ ,  $\beta_{2,0}$ ,  $\beta_{2,1}$ ,  $\alpha_{2,1}$ ,  $\beta_{2,2}$  y  $\alpha_{2,2}$ .

## VAR (P)

$$y_{1,t} = \beta_{1,0} + \beta_{1,1}y_{1,t-1} + \alpha_{1,1}y_{2,t-1} + \cdots + \beta_{1,p}y_{1,t-p} + \alpha_{1,p}y_{2,t-p} + \epsilon_{1,t}$$

$$y_{2,t} = \beta_{2,0} + \beta_{2,1}y_{2,t-1} + \alpha_{2,1}y_{1,t-1} + \cdots + \beta_{2,p}y_{2,t-p} + \alpha_{2,p}y_{1,t-p} + \epsilon_{2,t}$$

Note que:

AR( $p$ )

Tenemos que estimar:  $p + 1$  parámetros.

VAR( $p$ )

Tenemos que estimar:  $2(2p + 1)$  parámetros.



# Modelo de vectores autorregresivos (VAR)

- La notación más frecuente en los libros es:

$$Y_{1,t} = \beta_{1,0} + \sum_{i=1}^{p_1} \gamma_{1,i} Y_{2,t-i} + \sum_{i=1}^{p_2} \alpha_{1,i} Y_{1,t-i} + u_{1,t}$$
$$Y_{2,t} = \beta_{2,0} + \sum_{i=1}^{p_1} \gamma_{2,i} Y_{1,t-i} + \sum_{i=1}^{p_2} \alpha_{2,i} Y_{2,t-i} + u_{2,t}$$

- Un requisito fundamental para poder estimar estas funciones es que **cada variable Y sea estacionaria**.
- Una alternativa, cuando la estacionariedad no sea el caso, es hacer alguna transformación tipo diferenciación, logarítmica o de retornos.
- En general,  $p_1 = p_2 = p$ , por lo cual, a un VAR con p-rezagos se le llama **VAR(p)**.

## ¿Cómo escoger el $p$ ?

- El modelo debe tener el número “correcto” de rezagos.
- Determinar el  $p$  es un trade-off entre la maldición de la dimensionalidad y modelos sencillos.

### **Muy pocos rezagos:**

Autocorrelación del error  
puede generar estimadores ineficientes

### **Muchos rezagos:**

Problemas de grados de libertad.

Los modelos se escogen mediante los criterios de AIC y BIC.

Modelos VARS son sencillos de estimar, debido a que solo es necesario correr  $N$  regresiones lineales. Esta es una de las razones por la cual modelos VARs son muy populares.

# Índice

Dependencia entre variables

Modelo de vectores autorregresivos (VAR)

Prueba de causalidad de Granger


Cointegración

Modelo de corrección de error vectoriales  
(VECM)

Aplicación

# Prueba de causalidad de Granger

- **Ejemplo: Precios de vivienda**
- Es una prueba de **causalidad predictiva** no de **causalidad real**.
- De acuerdo con la causalidad de Granger, si una señal  $X_1$  "Granger-causa" una señal  $X_2$ , entonces los valores pasados de  $X_1$  deben contener información que ayude a predecir  $X_2$  más allá de la información contenida en los valores pasados de  $X_2$  solamente. .
- Explota la especificación VAR para verificar si los rezagos de  $X$  son significativos en la predicción de  $Y$ , condicional a los rezagos de la misma  $Y$ .



# Prueba de causalidad de Granger

$$Y_{1,t} = \beta_{1,0} + \sum_{i=1}^p \gamma_{1,i} Y_{2,t-i} + \sum_{i=1}^p \alpha_{1,i} Y_{1,t-i} + u_{1,t} \quad (1)$$

$$Y_{2,t} = \beta_{2,0} + \sum_{i=1}^p \gamma_{2,i} Y_{1,t-i} + \sum_{i=1}^p \alpha_{2,i} Y_{2,t-i} + u_{2,t} \quad (2)$$

- En particular, consiste en hacer prueba de hipótesis de los coeficientes de la ecuación  $Y_1$  asociados a las variables  $Y_2$ .
- Posibles pruebas de Granger sobre la ecuación 1:
- Significancia individual: ¿El rezago  $Y_{2,t-k}$  es significativo para la predicción de  $Y_{1,t}$ ?

$$H_0: \gamma_{1,k} = 0$$

$$H_0: \gamma_{1,k} \neq 0$$

Estadístico de prueba se distribuye t-student

- Significancia conjunta: ¿Los rezagos de 1 a p de  $Y_{2,t}$  son significativos en el pronóstico de  $Y_{1,t}$ ?

$$H_0: \gamma_{1,1} = \gamma_{1,2} = \dots = \gamma_{1,p} = 0$$

$$H_0: \gamma_{1,k} \neq 0 \text{ para algun } k$$

Estadístico de prueba se distribuye F

# Índice

Dependencia entre variables

Modelo de vectores autorregresivos (VAR)

Prueba de causalidad de Granger

Cointegración

Modelo de corrección de error vectoriales  
(VECM)

Aplicación

# Cointegración

- **Orden de integración ( $I(d)$ ):** estadístico de resumen, que informa el número mínimo de diferencias requeridas para obtener una serie estacionaria de covarianza.
- Como se mencionó previamente, una forma de lidiar con la no estacionariedad para poder estimar modelos autorregresivos univariados y multivariados (como el VAR(p)) es transformar la serie de tiempo.
- Una segunda estrategia, para el caso multivariado, es **formar combinaciones lineales de estas**.
- **Cointegración:** combinaciones lineales estacionarias de series **no** estacionarias.
- **Se dice que dos series Y y X son cointegradas si ambas son  $I(d)$  y existe una combinación lineal que es  $I(0)$ .**

# Cointegración

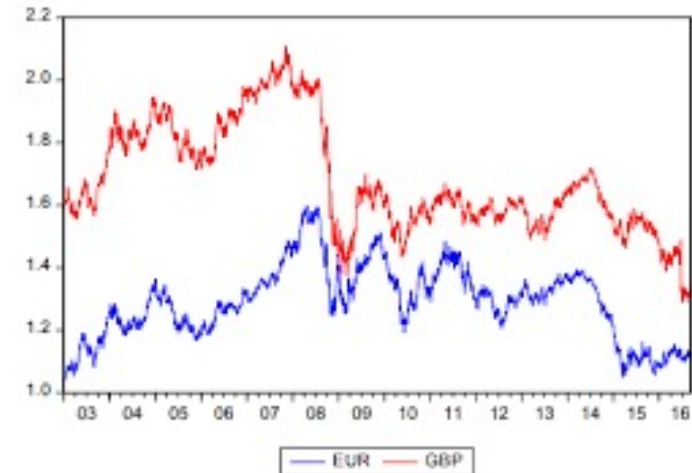
- **Orden de integración (I (d)):** estadístico de resumen, que informa el número mínimo de diferencias requeridas para obtener una serie estacionaria de covarianza.

Sean las variables  $X_t \sim I(1)$  y  $Y_t \sim I(1)$

Una combinación lineal de estas variables que sea estacionaria.

$$Y_t = \beta_0 + \beta_1 X_t + \epsilon_t$$

Entonces, se dice que las variables Y, X están cointegradas si esta es  $I(0)$





# Cointegración

- En la vida real hay muchos ejemplos de estas relaciones de largo plazo:
  - Inflación y Desempleo.
  - Estructura de plazos de la tasa de interés.
  - Diferenciales precios de los combustibles.
  - **Hipótesis de ingreso permanente.**

# Cointegración

- La cointegración implica un conjunto de equilibrios dinámicos de largo plazo donde los pesos usados para lograr la estacionariedad representan la relación de equilibrio.
- Un sistema de series cointegradas permite especificar las dinámicas de corto y largo plazo. Este modelo se conoce como Vector Error Correction Model (VECM).
- Este modelo permite identificar y parametrizar esas relaciones de largo plazo en series no estacionarias, información que se hubiera perdido en las transformaciones necesarias para volver las series estacionarias y calcular un VAR(p).

# Cointegración

- Hipótesis de ingreso permanente: relación de largo plazo entre ingreso real y consumo real.

$$\ln(cr)_t = \beta_c + \beta_y \ln(yr)_t + u_t$$


$cr$ : consumo real.

$yr$ : ingreso real.

$\beta_c, \beta_y$ : relación de largo plazo

$u_t$ : término de error (desviación de corto plazo).

# Cointegración



# Cointegración

- Una de las pruebas más famosas de cointegración para dos (o N) variables es la de Engel y Granger (1987), que consta de 2 pasos.
- Suponiendo que tiene las variables  $Y_t$  y  $Z_t$ :
  1. Utilizando pruebas Dickey Fuller de raíz unitaria, verifique si las series son **integradas del mismo orden**. En caso de no serlo **no** son **cointegradas**.
  2. **Estime** la relación de **equilibrio** y verifique que las **desviaciones** de corto **plazo** son estacionarias.

$$Y_t = \beta_c + \beta_y Z_t + \epsilon_t$$

Hacer pruebas de raíz unitaria sobre  $\hat{\epsilon}_t$ .

# Índice

Dependencia entre variables

Modelo de vectores autorregresivos (VAR)

Prueba de causalidad de Granger

Cointegración

Modelo de corrección de error vectoriales  
(VECM)

Aplicación

# Modelo de corrección de error vectoriales


- Considere un modelo con dos variables  $I(1)$ ,  $Y_{1,t}$  y  $Y_{2,t}$  y la siguiente relación de largo plazo:

$$Y_{1,t} = \beta_0 + \beta_1 Y_{2,t} + u_t$$

- $Y_{1,t} = \beta_0 + \beta_1 Y_{2,t}$  es el equilibrio de largo plazo.
- $u_t$  son las desviaciones de corto plazo (que se suponen estacionarias y por tanto las series están cointegradas).
- Revisemos el caso  $\beta_1 > 0$ .

# Modelo de corrección de error vectoriales

- Partamos del punto de equilibrio A.
- Un choque positivo de corto plazo en el periodo anterior  $u_{t-1} > 0$  lleva  $Y_{1,t}$  al punto C sin afectar  $Y_{2,t}$ .
- Hay 3 trayectorias posibles para volver al equilibrio, las cuales se quieren rescatar con el modelo VECM.





# Modelo de corrección de error vectoriales

- Suponiendo que los **movimientos de corto plazo** de  $Y_{1,t}$  y  $Y_{2,t}$  son una función lineal de las desviaciones de equilibrio se tiene que:

$$Y_{1,t} - Y_{1,t-1} = \gamma_1 u_{t-1} + v_{1,t} = \gamma_1 (Y_{1,t-1} - \beta_0 - \beta_1 Y_{2,t-1}) + v_{1,t}$$
$$Y_{2,t} - Y_{2,t-1} = \gamma_2 u_{t-1} + v_{2,t} = \gamma_2 (Y_{1,t-1} - \beta_0 - \beta_1 Y_{2,t-1}) + v_{2,t}$$

- Si  $\gamma_1 < 0$  y  $\gamma_2 = 0$ , se observaría la trayectoria hacia A.
- Si  $\gamma_1 = 0$  y  $\gamma_2 > 0$ , se observaría la trayectoria hacia B.
- Si  $\gamma_1 \neq 0$  y  $\gamma_2 \neq 0$ , se observaría la trayectoria hacia algún punto D.

# Modelo de corrección de error vectoriales

- Se puede controlar por rezagos de las mismas variables del sistema (en su transformación estacionaria):

$$\Delta Y_{1,t} = \gamma_1(Y_{1,t-1} - \beta_0 - \beta_1 Y_{2,t-1}) + \sum_{i=1}^p \alpha_{1,i} \Delta Y_{1,t-i} + \sum_{i=1}^p \phi_{1,i} \Delta Y_{2,t-i} + v_{1,t}$$
$$\Delta Y_{2,t} = \gamma_2(Y_{1,t-1} - \beta_0 - \beta_1 Y_{2,t-1}) + \sum_{i=1}^p \alpha_{2,i} \Delta Y_{2,t-i} + \sum_{i=1}^p \phi_{2,i} \Delta Y_{1,t-i} + v_{2,t}$$

- Note que es una especificación bastante parecida a la especificación del VAR(p) pero controlando por el equilibrio de largo plazo, esta es la información que se pierde en el VAR vs el VECM cuando las series son cointegradas.

# Modelo de corrección de error vectoriales

- Re organizando se tiene que:

$$\begin{aligned}\Delta Y_{1,t} &= -\gamma_1 \beta_0 + \gamma_1 Y_{1,t-1} - \gamma_1 \beta_1 Y_{2,t-1} + \sum_{i=1}^p \alpha_{1,i} \Delta Y_{1,t-i} + \sum_{i=1}^p \phi_{1,i} \Delta Y_{2,t-i} + v_{1,t} \\ \Delta Y_{2,t} &= -\gamma_1 \beta_0 + \gamma_1 Y_{1,t-1} - \gamma_1 \beta_1 Y_{2,t-1} + \sum_{i=1}^p \alpha_{2,i} \Delta Y_{2,t-i} + \sum_{i=1}^p \phi_{2,i} \Delta Y_{1,t-i} + v_{2,t} \\ \Delta Y_{1,t} &= -\pi_{1,0} + \pi_{1,1} Y_{1,t-1} - \pi_{1,2} Y_{2,t-1} + \sum_{i=1}^p \alpha_{1,i} \Delta Y_{1,t-i} + \sum_{i=1}^p \phi_{1,i} \Delta Y_{2,t-i} + v_{1,t} \\ \Delta Y_{2,t} &= -\pi_{2,0} + \pi_{2,1} Y_{1,t-1} - \pi_{2,2} Y_{2,t-1} + \sum_{i=1}^p \alpha_{2,i} \Delta Y_{2,t-i} + \sum_{i=1}^p \phi_{2,i} \Delta Y_{1,t-i} + v_{2,t}\end{aligned}$$

- Se puede estimar en una sola etapa como un VAR(p) con los controles y restricciones respondientes, o estimar en una primera etapa el equilibrio de largo plazo e incluir como control en el VAR(p) las desviaciones de corto plazo en una segunda etapa.

## Referencia

- González y Hernández (2016). Impactos indirectos de los precios del petróleo en el crecimiento económico colombiano. Recuperado de: [http://www.scielo.org.co/scielo.php?script=sci\\_arttext&pid=S0120-25962016000100004#4](http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S0120-25962016000100004#4)
- Wills, D. (2018). Pronóstico en finanzas, economía y otros. Clase posgrado Universidad de los Andes.
- Enders, W(2014). Applied Econometric Time Series. Recuperado de: <https://www.wiley.com/en-us/Applied+Econometric+Time+Series%2C+4th+Edition-p-9781118808566>

# Gracias



quantil

matemáticas aplicadas