

No. 7

ABRIL de 2018

quantil

ISSN 1234-5790 Edición electrónica

**Documentos
de Trabajo**

Predicción del Mercado de TES en el Corto Plazo

Erick Translateur

Serie Documentos de Trabajo Quantil, 2018-10
Edición electrónica.

ABRIL de 2018

Comité editorial:

Álvaro J. Riascos, CoDirector General y Director Modelos Económicos e I&D
Diego Jara, CoDirector General y Director Matemáticas Financieras
Juan Pablo Lozano, Director Asociado Matemáticas Financieras
Natalia Iregui, Directora Administrativa
Simón Ramírez, Director de Tecnologías de la Información
Mateo Dulce, Investigador

© 2018, Quantil S.A.S., Matemática Financiera,
Carrera 7 # 77 - 07. Oficina 901, Bogotá, D. C., Colombia
Teléfonos: 3718132 – (310)6791459 – (320)8461236
E-mail: info@quantil.com.co
<http://www.quantil.com.co>

Impreso en Colombia – Printed in Colombia

La serie de Documentos de Trabajo Quantil se circula con propósitos de discusión y divulgación. Los artículos no han sido evaluados por pares ni sujetos a ningún tipo de evaluación formal por parte del equipo de trabajo de Quantil.

Publicado bajo licencia:



Atribución – Compartir igual

Creative Commons: <https://co.creativecommons.org>

Predicción del Mercado de TES en el Corto Plazo

Erick Translateur

Resumen

En el presente trabajo se estudia la hipótesis de caminata aleatoria para el mercado colombiano de bonos gubernamentales (TES). En el estudio se encuentra que es posible predecir el precio en el corto plazo, por lo que se rechaza la hipótesis de caminata aleatoria para dicho mercado. Lo anterior se concluye por medio de un algoritmo de *trading* intradía, basado en modelos de aprendizaje de máquinas, al cual se le realiza un *Backtest* y se concluye que los retornos esperados son superiores a los costos de transacción. A su vez, se realiza un *Backtest* del algoritmo sobre el mercado norteamericano y se observa que en dicho mercado los retornos esperados son significativamente menores. Es de resaltar que adicional a las implicaciones académicas, el algoritmo tiene aplicaciones empíricas ya que puede ser utilizado como una estrategia de inversión.

Palabras claves: Eficiencia de Mercados, TES, Algoritmo de Trading, Minería de Datos. Códigos JEL: G14, G17, C02, C21

1. Introducción

Los mercados financieros son una parte fundamental para el buen desarrollo de las economías mundiales ya que permiten realizar una mejor distribución de los recursos entre quienes desean ahorrar y quienes desean invertir. Por lo tanto, los países desarrollados han logrado alcanzar mercados que se caracterizan por ser profundos y eficientes. Por otra parte, mercados ineficientes pueden traer altos costos económicos y sociales; por ejemplo, la ineficiencia de un mercado genera costos adicionales de transacción para los individuos y altos costos de financiación para las compañías y la Nación. De esta forma, señales de ineficiencia deberían ser tomadas en cuenta por los encargados de política, quienes deberían dar solución a las causas de la ineficiencia fomentando el uso de los mercados y eliminando las obstrucciones o regulaciones que estén generando dichas ineficiencias.

En esta línea, la eficiencia de los mercados ha sido estudiada a profundidad en la literatura. La Hipótesis de Mercados Eficientes (HME) surge a través del trabajo realizado por Eugene Fama (1970) *“Efficient Capital Markets: A Review of Theory and Empirical Work”*. En este, basándose en una serie de tests, se demuestra que los principales mercados financieros del mundo son eficientes. En ellos, se evalúan tres principales definiciones de eficiencia: en la primera definición, un mercado se considera eficiente si el precio siempre refleja toda la información disponible; en la segunda, un mercado es eficiente si los precios se ajustan eficientemente ante la llegada de nueva información de mercado; por último, la tercera definición sustenta que un mercado es eficiente si no existen grupos de agentes con información privilegiada. Para analizar el cumplimiento del primer enfoque de eficiencia se desarrolló la hipótesis de caminata aleatoria. Si el precio siempre refleja toda la información disponible, no es posible predecir el precio del activo para un periodo futuro, por lo que el precio debería seguir una caminata aleatoria.

De la anterior línea de pensamiento surgió la hipótesis de caminata aleatoria. Esta fue utilizada para comprobar la HME por varias décadas; sin embargo, la literatura más reciente ha encontrado que el incumplimiento de la hipótesis de caminata aleatoria no implica necesariamente ineficiencia de mercado. Diferentes estudios como Chordia, Roll y Subrahmanyam (2007), Lo, Mamaysky y Wang (2000), Campbell, Lo y MacKinlay (1997) y Dacorogna, Gençay, Müller, Olsen y Pictet (2001) demostraron que aún los mercados más eficientes no siguen una caminata aleatoria puesto que en el corto plazo existe cierto nivel de predicción en el precio. A pesar de ello, la literatura tiende a respaldar la HME y argumenta que la predictibilidad del precio de los activos solo ocurre en el corto plazo y tiende a desaparecer. Lo y MacKinlay (2002) sustentan que el descubrimiento de una herramienta capaz de predecir el precio de un activo es equiparable a la inversión sobre el descubrimiento de una vacuna. Una vez descubierta, se espera que la vacuna genere retornos esperados positivos durante cierto tiempo para recuperar la inversión y generar ganancias equivalentes al riesgo asumido. Un mercado eficiente debería ser capaz de introducir este nuevo desarrollo y tender a reducir los retornos de dicha herramienta en

un mediano plazo. Lo mismo sucede con los avances tecnológicos en el mundo financiero. Cuando el poder computacional creció significativamente, nuevas herramientas fueron creadas para predecir el precio de los activos. No obstante, los retornos positivos de las nuevas herramientas atrajeron agentes capaces de explotar dichas ventajas, reduciendo el poder predictivo de los nuevos modelos. En otras palabras, la predictibilidad del precio de mercado está directamente ligada a un costo, ya sea tecnológico o de investigación de nuevos modelos. A pesar de los anteriores hallazgos, la literatura no ha trazado una línea divisoria para determinar hasta qué punto la predictibilidad del precio no es considerada ineficiencia de mercado.

Teniendo en cuenta los anteriores puntos, el principal resultado de este documento es demostrar que el mercado de TES rechaza la hipótesis de caminata aleatoria, dado que es posible predecir en el corto plazo el precio del activo. A diferencia de los estudios encontrados en la literatura, la presente investigación rechaza la hipótesis de caminata aleatoria por medio de un Backtest (de más de 4 años) y no por medio de pruebas estadísticas. Utilizando un algoritmo de *trading*, basado en máquinas de aprendizaje (*machine learning*), se demuestra que el precio de las 3 referencias más líquidas de los TES es lo suficientemente predecible para generar una estrategia de inversión con retornos esperados superiores a los costos de transacción. Resalta que el poder predictivo del algoritmo es bastante alto y estable en el tiempo; en el mejor Backtest se logra obtener una probabilidad de acierto 2.95 veces mayor a la probabilidad de desacierto. Adicional a esto, se da robustez a los resultados al comparar el desempeño del algoritmo en el mercado colombiano con el de los Estados Unidos y al realizar un Backtest sobre el spread entre dos referencias de TES. Es de resaltar que en el mercado norteamericano el desempeño del algoritmo es significativamente inferior, por lo que se considera que el rechazo de la hipótesis de caminata aleatoria en el caso de los TES es una evidencia de ineficiencia de mercado; no obstante, dado que no existe en la literatura pruebas determinantes para ello, esta investigación se dejará para futuros estudios. Por último, adicional a las implicaciones académicas, el algoritmo tiene aplicaciones empíricas ya que puede ser utilizado como una estrategia de inversión

Este documento se estructura en cuatro partes. Primero, se presenta un breve resumen de las metodologías de análisis de eficiencia existentes hasta el momento; segundo, se expone la situación actual del mercado financiero colombiano, los datos y los supuestos utilizados; tercero, se plantean los distintos algoritmos de *trading* utilizados para comprobar la hipótesis de caminata aleatoria; por último, se presentan los principales resultados y conclusiones junto a posibles estudios futuros.

2. Revisión de literatura

El trabajo de Eugene Fama (1970) es una compilación de varios trabajos expuestos en su época; sus estudios han sido pioneros en tanto de ellos surge la Hipótesis de los Mercados

Eficientes. En esta hipótesis se define a un mercado eficiente como aquél en el que el precio siempre refleja completamente toda la información disponible del mercado. De esta forma, se argumenta que si un mercado es eficiente y el precio refleja toda la información disponible, su comportamiento futuro no es predecible. Sin embargo, este no es el único concepto de eficiencia que se presenta. Por ejemplo, si el precio actual refleja toda la información disponible, se podría estudiar qué sucede cuando llega nueva información. Entonces, otro análisis sería observar qué tan eficientemente un mercado adapta o incorpora nueva información de mercado. Por otro lado, tras haber estudiado los dos anteriores casos, también se contempla la existencia de monopolios de información. Un ejemplo, sería determinar la existencia de grupos selectos con información privilegiada que no todo el mercado tiene.

De acuerdo con la anterior discusión, el trabajo de Fama (1970) se divide en tres tipos de tests: los test de forma débil (*weak form*), de forma semifuerte (*semi-strong form*), y por último, los test de forma fuerte (*strong form*). En primer lugar, los test de forma débil evalúan si el precio actual refleja toda la información disponible. Estos principalmente se basan en ver si es posible pronosticar a futuro el valor del activo. Debido a que en la literatura no se encontraron resultados significativos de ineficiencia de mercados en los tests de forma débil, la literatura se tornó a testear la eficiencia con la que el precio se adapta a nueva información. Estos tests son llamados de forma semifuerte (*semi-strong form*). Por último, los tests de forma fuerte (*strong form*) analizan la existencia de grupos dentro del mercado con información privilegiada.

Como ya se mencionó, los test de forma débil analizan si el precio de un activo siempre refleja toda la información disponible de mercado. Si esto sucede, no sería posible predecir el precio de un mercado puesto que no habría información adicional que no estuviera incorporada en el precio actual. No obstante, una de las principales limitantes de este tipo de test es la definición de “toda la información de mercado”. De hecho, el conjunto de información estará limitado a la teoría de precios que se desee utilizar. Esta teoría dependerá de los demás activos incluidos en ella y el periodo histórico utilizado para calibrar sus parámetros. La literatura ha desarrollado varias formas de definir la información de mercado. Sin embargo, la presente investigación se basa en la principal línea de análisis de los tests de forma débil: la hipótesis de la caminata aleatoria. Esta teoría se explica brevemente a continuación.

2.1. Hipótesis de la Caminata Aleatoria

Siguiendo a Campbell et al. (1997) los test de forma débil se basan en tres versiones de la hipótesis de caminata aleatoria: incrementos en el precio independiente e idénticamente distribuidos (IID) o caminata aleatoria 1 (RW1, por sus siglas en inglés); incrementos independientes no idénticamente distribuidos (INID) o caminata aleatoria 2 (RW2); por último, incrementos no correlacionados o caminata aleatoria 3 (RW3). Para los tres casos, los test solo incluyen información histórica del precio del activo; no obstante, si

sólo con la información histórica del mismo activo se logra predecir el precio futuro, se esperaría que con aún más información los resultados se mantendrían.

2.1.1. Caminata Aleatoria 1: Incrementos IID

El modelo de caminata aleatoria 1 afirma que, debido a que el precio actual refleja toda la información disponible, los cambios del precio de un periodo a otro son independientes entre sí. Además, estos cambios en precio son idénticamente distribuidos.

Sea p_t el logaritmo del precio de un activo en el periodo t (tiempo discreto). Entonces, la Ecuación (1) describe el comportamiento del precio a través del tiempo.

$$p_t = \mu + p_{t-1} + e_t \quad \text{donde } e_t \sim IID \mathcal{N}(0, \sigma^2), \quad (1)$$

donde e_t es el término del error que se distribuye normal con media 0 y varianza σ^2 . Por su parte, μ representa la tendencia del precio, que está asociada al riesgo del activo. Es de notar que esto hace que el precio no sea estacionario a través del tiempo. Por tal motivo, cuando se hace referencia a la predictibilidad de un mercado, tácitamente se está hablando sobre lograr predecir movimientos del precio con respecto a su tendencia μ . Para fines de esta investigación, dado que el periodo de predicción es de alrededor de 10 minutos, por simplicidad se asume que μ es igual a cero.¹

De igual forma, es de notar que la anterior ecuación permite afirmar que los cambios en el precio no están correlacionados entre ellos, al igual que cualquier transformación no lineal de estos.

El valor esperado y la varianza del precio (en logaritmo) para un periodo t se muestran en las Ecuaciones (2) y (3).

$$E[p_t | p_0] = p_0 + \mu_t. \quad (2)$$

$$Var[p_t | p_0] = \sigma_t^2. \quad (3)$$

Adicionalmente, el incremento esperado r_{t+1} (o retorno logarítmico esperado) en el periodo t para el periodo $t + 1$ condicionado a cualquier conjunto de información ϕ_t es igual su valor esperado incondicional:

$$E[p_{t+1} - p_t] = E[r_{t+1}] = E[r_{t+1} | \phi_t] = \mu. \quad (4)$$

Como ya se mencionó, ϕ_t representa cualquier conjunto de información que se desee utilizar. Éste puede incluir información de otros activos o únicamente la información del activo estudiado. El supuesto de que μ es constante a través del tiempo se puede

¹Para evitar calcular μ , que depende de la teoría de precios utilizada, se suele analizar el comportamiento del precio de un activo relativo al precio de otro activo. Esto se hace en la Sección 5.1.1.

relajar; sin embargo, la idea fundamental de la Ecuación (4) es que la mejor predicción del precio de un activo es igual al precio actual más una constante (que podría variar en el tiempo) asociada al riesgo del mismo.

2.1.2. Caminata Aleatoria 2: Incrementos INID

Suponer que la distribución de los cambios de los precios de un activo es constante en el tiempo es un supuesto fuerte. Por esta razón, la hipótesis de RW2 relaja este supuesto y permite a la distribución del error e_t cambiar durante distintos periodos. De esta forma, también se le permite a la volatilidad del error depender del tiempo incorporando heterocedasticidad a la volatilidad de los retornos de los activos financieros. A pesar de que RW2 es más débil que RW1, ésta sigue conteniendo la principal propiedad económica del modelo: no es posible crear una estrategia de inversión basándose en la historia del precio que presente retornos esperados por encima de μ , dado que no es posible predecir el precio.

Los tests utilizados para analizar la hipótesis de RW2 se pueden clasificar en dos tipos:

- Reglas de Filtros: Estos modelos consisten en crear reglas básicas de *trading* y analizar su desempeño comparado con el de mercado. No obstante, estas reglas son bastante básicas. Alexander (1961, 1964) las presentó como: un activo se compra si el precio incrementa $x\%$ y se mantiene hasta cierto umbral. Por otro lado, se toma una posición en corto si el precio cae $x\%$ y se liquida la posición en un nuevo umbral. A estas estrategias se les conoce como un filtro $x\%$. Fama (1965) y Fama y Blume (1966) mostraron que dichas estrategias presentaban un buen rendimiento para valores inferiores a 1% . No obstante, generaban tantas transacciones que los costos superaban las ganancias.
- Análisis técnico: Varios autores como Taylor y Allen (1992) y Lo, Mamaysky y Wang (2000) han demostrado que el análisis técnico ofrece información adicional de mercado que podría ser utilizada para generar una ventaja a la hora de tomar decisiones de inversión. Lo et al. (2000), tomando un periodo de 31 años para los mercados de Estados Unidos, muestran que “varios indicadores de análisis técnico realmente sí proveen incrementos en la información y podrían tener algún valor práctico”.

No obstante, las técnicas utilizadas para testear la hipótesis de RW2 son bastante simples y se basan en métodos por fuera del ámbito académico. Por tal motivo, este tipo de test no han tenido una gran acogida en la literatura.

Teniendo en cuenta lo anterior, la metodología que se propone en este documento tendría cabida en este rango de tests. No obstante, el aporte que se hace es ofrecer una herramienta técnica que involucra estadística no paramétrica (kernels de suavizamiento) y máquinas de aprendizaje (Logit, Random Forest y Support Vectors Machine) para demostrar que el precio de un activo sí es predecible, por lo que rechaza tanto RW1

como RW2.

Antes de continuar al modelo RW3, es importante abrir la discusión de cómo evaluar si una estrategia de inversión logra predecir el precio del activo o no. Por un lado, se esperaría que la estrategia genere retornos esperados positivos. Pero de igual forma, estos retornos deberían ser superiores a algún *benchmark*. Definir el *benchmark* correcto no es una tarea sencilla. Los modelos anteriormente explicados han sido comparados por la literatura contra la estrategia de *buy-and-hold*. El supuesto detrás de esta metodología de comparación es que el nivel de riesgo de la estrategia de *trading* es igual al nivel de riesgo del activo. Pero desconoce estrategias, como la mostrada en el presente texto, que solo retienen el activo por unos minutos al rededor de tres veces al día. En el presente documento no se espera responder directamente esta pregunta. Sin embargo, se muestran evidencias concluyentes de que los retornos esperados de la estrategia planteada son efectivamente causados por la posibilidad de predecir el precio en el corto plazo; lo cual es suficiente para rechazar RW2.

2.1.3. Caminata Aleatoria 3: Incrementos no correlacionados

La hipótesis de RW3 es la teoría de caminata aleatoria más general y reciente en la literatura. En esta no se supone ninguna distribución de los retornos; solamente se desea comprobar que la Ecuación (5) se mantiene.

$$Cov[e_t, e_{t-k}] = 0 \quad \forall k. \quad (5)$$

La Ecuación (5) ha sido testeada de varias formas. Las principales han sido correlogramas y pruebas de autocorrelación como las desarrolladas por Box y Pierce (1970) y Ljung y Box (1978). Sin embargo, dado que estas pruebas dependen del número de rezagos a incluir, se desarrolló la metodología de razones de varianzas (*variance ratios*). En Campbell et al. (2000) se presenta dicha metodología, la cual estudia la distribución de la razón entre varianzas. A continuación se realizará una descripción breve de ella, aunque no se utilizará en el presente trabajo.

Defínase $r_t(2) = r_t + r_{t-1}$. Entonces, la razón de varianzas $VR(2)$ es igual a la siguiente ecuación:

$$\begin{aligned} VR(2) &= \frac{Var[r_t(2)]}{2Var[r_t]} = \frac{Var[r_t + r_{t-1}]}{2Var[r_t]} \\ &= \frac{2Var[r_t] + 2Cov[r_t, r_{t-1}]}{2Var[r_t]} \\ VR(2) &= 1 + \rho(1), \end{aligned} \quad (6)$$

donde $\rho(1)$ es el coeficiente de autocorrelación de primer orden de los retornos r_t . Si

se desea que se cumpla RW3, es necesario que $VR(2)$ sea estadísticamente igual a 1. Existen varias formas para construir estadísticos para el análisis de $VR(2)$; de hecho, algunos logran incorporar heterocedasticidad en el término del error. A su vez, se puede generalizar dicha metodología para distintos $VR(q)$. Este tipo de tests han mostrado que, aun en mercados eficientes, existe correlación entre los retornos de los activos y sus valores pasados (ver Campbell et al. (2000), Lo y MacKinlay (1999) y Hodrea (2015)).

Por ejemplo, Lo y Mackinaly (1999) usaron datos semanales entre 1962 y 1985 del índice CRSP NYSE-AMEX y encontraron que en todo el periodo estudiado, al igual que en subperiodos de la muestra, el valor del coeficiente de autocorrelación de primer orden es aproximadamente igual a 30 % (utilizando razones de varianza). En esta misma línea, Roll (1984) muestra que aun cuando el precio de un activo sigue una caminata aleatoria y las transacciones solo ocurren entre las puntas (*ask* y *bid*), los cambios de precios resultantes siguen un proceso MA(1).

2.1.4. ¿Los mercados son eficientes?

La literatura sigue apoyando la HME para los principales mercados del mundo; sin embargo, reconoce la necesidad de adecuar la teoría a los recientes hallazgos. Es de recordar que hasta el momento se ha demostrado que la teoría de caminata aleatoria no se cumple debido a la existencia de cierto nivel de predictibilidad en los precios de los activos. A pesar de ello, varios autores sostienen que esta predictibilidad es consecuencia de factores racionales específicos de los agentes del mercado, que son consistentes con la eficiencia de mercado (Dacorogna et al. (2001)). La principal dificultad es que en la literatura no se ha establecido una línea divisoria que permita definir hasta qué punto la predictibilidad observada no es considerada como una señal de ineficiencia.

Dada las anteriores afirmaciones, la presente investigación únicamente rechaza la hipótesis de caminata aleatoria. No obstante, se considera que para el caso colombiano el rechazo de la hipótesis de caminata aleatoria es una señal de ineficiencia de mercado, por lo que se deja para trabajos futuros establecer una definición de eficiencia que permita determinar si el mercado de TES es eficiente o no. La principal razón de ello es que el nivel de predictibilidad en el mercado de TES es relativamente alto y estable a través del tiempo. En esta línea, algunos autores afirman que la eficiencia debería ser medida en términos relativos (Farmer y Lo (1999)). Cuando se habla de la eficiencia de un motor no se espera que la máquina sea 100 % eficiente, simplemente se prefiere un motor con un nivel de eficiencia del 40 % sobre uno del 30 %. Por tal motivo, en la Sección 5.1.1 se compara el desempeño del algoritmo de *trading* en el mercado de TES y en el de Bonos Gubernamentales de los Estados Unidos. En la comparación se observa que el mercado de TES es significativamente más predecible que el mercado norteamericano. Por otra parte, en el Anexo D se presentan los resultados mensuales del backtest y se concluye que la predictibilidad del mercado de TES ha sido constante durante los últimos 5 años. Por estas razones, se cree que lo observado en el estudio no es solamente el rechazo de

la hipótesis de caminata aleatoria, sino también, una señal de ineficiencia de mercado; esto se explorara en futuras investigaciones. Antes de entrar a los modelos desarrollados, a continuación se presenta un breve resumen de literatura para el mercado accionario colombiano.

2.2. Estudios de eficiencia en Colombia

Para el caso colombiano se observan distintas metodologías de prueba de eficiencia del mercado accionario. Ojeda y Castaño (2014) utilizan un modelo autorregresivo fraccionalmente integrado de medias móviles ARFIMA sobre el Índice General de la Bolsa de Valores de Colombia y concluyen que el IGBC no respeta la hipótesis de martingala, por lo que el mercado rechaza la hipótesis de eficiencia en el sentido débil. Por su parte, Worthington y Higgs (2003) estudian para Latinoamérica, incluyendo a Colombia, el comportamiento de tests tipo Dickey-Fuller, KPSS y razones de varianzas y encuentran que ningún mercado latinoamericano sigue un proceso de caminata aleatoria. Trujillo (2015) analiza la eficiencia de las acciones de Ecopetrol y Bancolombia por medio de estrategias de *trading* basadas en *spreads* y modelos estadísticos; en su investigación encuentra resultados similares a los anteriores. También se han realizado estudios de eventos. Gómez y Melo (2014) estudian el efecto del anuncio de problemas de liquidez de la principal comisionista de bolsa colombiana, Interbolsa. Este estudio concluye que los retornos de los activos financieros del país fueron afectados significativamente por dicho evento. Este tipo de estudios están ligados a los test de forma semifuerte que en el presente documento no se explicaron.

De los anteriores estudios resalta que no se ha analizado la eficiencia del mercado de TES que representa más del 75 % del volumen transado en la Bolsa de Valores de Colombia. Para ofrecer un mejor contexto, a continuación se presenta una breve descripción del mercado a analizar, los datos y los supuestos utilizados.

3. Mercado colombiano, datos y supuestos

En el caso colombiano, como en muchos otros países en vía de desarrollo, los mercados financieros están caracterizados por su falta de liquidez y profundidad. Adicionalmente, esta falta de profundidad de los mercados financieros se ha visto incrementada tras la crisis del 2008 y la caída de Interbolsa. Estos dos acontecimientos han generado una mayor aversión de los inversionistas a utilizar sus recursos en los mercados financieros colombianos. Como se puede observar, en el reporte mensual de la Bolsa de Valores de Colombia (BVC) de enero de 2016, en enero de 2015 se operaba en promedio \$83,67 billones en la BVC, mientras que para finales de 2015 este monto se redujo a \$55,1 billones.

Por su parte, en la Figura (1) se observa que el 75,37% del total negociado en la BVC corresponde a transacciones de TES, alrededor de \$15,02 billones mensuales para diciembre de 2015.² Lo anterior muestra que el mercado financiero colombiano, en su mayoría, está representado por el mercado de deuda pública.




Figura 1: Participación porcentual de monto transado para diciembre de 2015. Fuente: BVC.

Los TES en Colombia pueden ser transados en el Sistema Electrónico de Negociación (SEN) administrado por el Banco de la República y en el Mercado Electrónico Colombiano (MEC) administrado por la Bolsa de Valores de Colombia. En el SEN pueden transar los creadores de mercado como el Banco de la República y los principales bancos del país. En el MEC pueden negociar además de los creadores de mercado, las corredoras de bolsa, compañías de financiamiento, entre otros. Los datos del SEN son públicos y se encuentran en la página del Banco de la República; por su parte, los datos del MEC fueron ofrecidos por una corredora de bolsa local.³ Es de resaltar que estos mercados coexisten, por lo que se juntaron ambas bases de datos para tener un análisis completo.

Los datos utilizados son las series *intraday* de los precios de los TES con vencimiento 24 de julio de 2024. El periodo utilizado comprende desde julio primero de 2011 hasta marzo 31 de 2016. Estos datos incluyen el monto operado de cada una de las transacciones, la tasa de transacción (precio) y la hora exacta de su operación. Se tomaron los TES 24's debido a que son los bonos más líquidos.⁴ No obstante, se espera que si se rechaza la

²La BVC diferencia entre montos operados y montos negociados. Los primeros incluyen registro de operaciones, mientras que los segundos no.

³La corredora de bolsa AFIN, mediante la consultora de matemáticas aplicadas Quantil, fue quien ofreció los datos para la investigación por lo que se le agradece por su colaboración

⁴A partir de mediados de 2011 los TES 24 se convirtieron en el bono de 10 años de referencia y se han mantenido hasta la fecha a pesar de que su expiración sea menor a 8 años.

hipótesis de caminata aleatoria en este tipo de TES, en los TES de menor liquidez la conclusión será la misma. De hecho, el algoritmo fue utilizado para predecir el precio de los bonos que vencían a mediados de 2016 y los resultados se mantuvieron. El volumen mensual transado de TES 24 se observa en la Figura (2).




Figura 2: Nocional mensual transado en el SEN y el MEC de TES 24s. Fuente: AFIN y Banco de la República. Cálculos del Autor.

Por facilidad, para el procesamiento de datos se toma como variable la tasa de mercado (yield), en vez del precio; no obstante, por convención en la literatura y facilidad para el lector, la teoría se desarrollará en términos de precios. Como referencia, ganar un punto básico, sobre un nocional de \$1,000 millones, era alrededor de \$1'000,000 cuando los TES tenían una duración de 10 años; sin embargo, a medida que se acerca la fecha de vencimiento (2024) el valor de un punto básico decrece. Actualmente es de alrededor de \$615,000.

Es de observar que no se tiene información de puntas de mercado (*bid* y *ask*), como consecuencia es necesario plantear los siguientes supuestos.

3.1. Supuestos

Debido a que el mercado colombiano es ilíquido, se observan varias características específicas de este mercado que vale la pena resaltar. El mercado de TES se caracteriza por largos periodos sin transacciones, seguidos por cortos periodos de alto volumen de transacción. En la muestra existen 1,143 días y cada día está compuesto por 300 minutos de operación. De estos 342,900 minutos de operación, 205,527 no presentan transacción alguna. Cuando se toma la media del volumen transado por minuto, incluyendo los minutos sin transacción, se obtiene un valor de \$2.58 mil millones; al retirar los minutos

sin transacción, el valor asciende a 6.44 mil millones.

Con el fin de hacer un Backtest robusto es necesario respetar el orden de llegada de la información. Por tal motivo, se debe simular, con la información que se tendría en cada momento del Backtest, lo que el algoritmo podría haber efectivamente realizado. Debido a que no se tiene información de las puntas de mercado (*bid* y *ask*), el principal supuesto que se hace es que en los intervalos de tiempo que no se observan transacciones, el precio de mercado es igual al último precio observado. No obstante este supuesto no es tan relevante como parece; si se toma la tarea de observar una pantalla de *trading*, se puede ver que las puntas de mercado no se mueven significativamente cuando no hay operaciones.

De igual forma, para mitigar el impacto del supuesto, solo se le permite al algoritmo abrir una posición cuando acaba de ocurrir una transacción hace menos de un minuto. Dada la dinámica de *trading* explicada anteriormente, cuando acaba de ocurrir una transacción es muy probable que se pueda transar a ese mismo precio, de hecho existiría la posibilidad de transar a un precio más favorable. No obstante, para cerrar una posición sí es permitido hacerlo en cualquier momento al último precio reportado. Esta asimetría surgió por facilidad en el procesamiento de datos.

El siguiente supuesto principal es que las acciones que realizaría el algoritmo no afectarían el precio futuro. Para esto, los cálculos que se van a realizar serán basados en suponer que el algoritmo puede invertir en un nocional máximo de \$1,000 millones de pesos; cuando se tiene una posición abierta solo se puede mantener o cerrar la posición, no se puede aumentar el nocional. Como se observa en la Figura (3) en promedio se transan \$1.289 millones por transacción y se realizan 2 transacciones por minuto. De esta forma, se considera que una inversión máxima de un nocional de \$1,000 millones no alcanza a afectar las puntas. Es de notar que un nocional de \$1,000 millones es un monto bajo (el monto mínimo por transacción es de \$500 millones); no obstante, existe una posibilidad limitada de reescalar la inversión sin afectar las puntas considerablemente.

Por último, debido a que existen altas volatilidades al comienzo y final de la jornada de *trading*, al algoritmo no se le permite abrir ninguna posición sino hasta 30 minutos después de la apertura de mercado (8:30a.m.) y 30 minutos antes del cierre (12:30p.m.). A su vez, este debe cerrar su última posición a más tardar a las 12:40p.m. El propósito de estas reglas es evitar tomar posiciones *overnight* que requerirían supuestos adicionales para calcular su PyG. Con esta información, a continuación se presentan las diferentes estrategias de *trading* utilizadas en la investigación.

4. Estrategias de trading

En este documento solo se mostrarán las metodologías más relevantes de la investigación. Lo anterior dado que se probaron más de 10 formas de realizar una estrategia de




Figura 3: Número de lotes de \$1,000 millones por transacción observada (por facilidad visual se eliminó la barra correspondiente a 0). Fuente: AFIN y Banco de la República. Cálculos del autor.

trading con distintas herramientas estadísticas de predicción. Entre estas herramientas estadísticas se encuentran los modelos Logit, Random Forest, y Support Vectors Machine (SVM).

Inicialmente se mencionó que el procesamiento de los datos y los resultados por facilidad se desarrollaron con la tasa de mercado en vez del precio del bono. Sin embargo, por convención en la literatura y facilidad para el lector, la notación está en términos del precio del activo (existe una relación inversa entre tasa y precio de mercado). Es de notar que una vez se tiene uno de los dos valores, se puede obtener directamente el otro.

De forma general, todas las estrategias estudiadas se pueden resumir de la siguiente forma: Sea $f^\tau(\Phi_t)$ una función (ya sea el modelo logit, los árboles de decisión o SVM) que toma como argumento de entrada la información histórica (ϕ_t) del precio del activo, conocida hasta el momento t , y que predice una variable z :

$$z = f^\tau(\Phi_t). \quad (7)$$

z es una variable discreta en el caso del modelo Logit; para Random Forest y SVM, z es una variable continua que sigue el cambio en la tasa del bono. Por su parte, τ representa el horizonte de tiempo de pronóstico y está medido en minutos y tiempo discreto; también t está medido en minutos y tiempo discreto. De esta forma, las estrategias de *trading* consisten en tomar una decisión de compra, venta o espera dependiendo del valor de z . Los algoritmos solo pueden comprar o tomar una posición en corto cuando no se tienen ninguna posición abierta. Una vez se abre la posición, las únicas decisiones que

puede tomar el algoritmo es mantener la posición hasta $t + 1$ o cerrarla; no se permite duplicar una posición.

Para el modelo logit, las decisiones son directas dependiendo de la categoría generada por $f^\tau(\Phi_t)$ (ver Sección 4.2.1). En el caso de los modelos con variable de salida continua, la decisión de compra o venta se toma a partir de umbrales que dependen de las predicciones históricas del modelo (ver Secciones 4.2.2 y 4.2.3).

Para todos los modelos, el mercado se revisa cada minuto. Cuando se decide comprar el activo, éste se retiene hasta el periodo $t + 1$. En $t + 1$ se debe predecir de nuevo $f^\tau(\Phi_{t+1})$ y volver a tomar la decisión. Este proceso se repite hasta que $f^\tau(\Phi_t)$ cruce un nuevo umbral, en el caso en que z sea una variable continua, o que tome la categoría correspondiente a cerrar la posición. En ambos casos, se vende el activo. Como ya se mencionó, es posible tomar una posición en corto para generar ganancias cuando el mercado está cayendo. En dado caso, la estrategia consiste en revisar el mercado cada minuto, recalcular z y decidir si se cierra la posición o se mantiene hasta el siguiente minuto.

Para determinar el valor de τ se realizaron varios Backtest para distintos valores (1, 2, 3, 5, 8, 10, 15 y 20 minutos). Dependiendo de los resultados en el Backtest, para cada modelo se selecciona un τ distinto. A este punto, vale la pena aclarar que varios de los parámetros de los modelos fueron escogidos sin realizar un proceso de optimización robusto, por capacidad computacional. Por tal motivo, en trabajos futuros se realizarán procesos de optimización en aras de buscar mejores resultados.

En este orden de ideas, la riqueza del algoritmo dependerá de la función $f(\Phi_t)$ y en gran medida de lo que se tome como información Φ_t . Como ya se dijo, las funciones a utilizar fueron un modelo Logit, un Random Forest y un SVM; no obstante, se entrará un poco más al detalle de cada uno cuando se muestren sus resultados.

4.1. Variables de entrada

Es preciso aclarar que tanto la estrategia como las variables de entrada varían para cada uno de los modelos y fueron escogidas dependiendo de su desempeño en los Backtest. De hecho, trabajos futuros también podrían incluir procesos de optimización robustos para la selección de variables.

De forma general, las variables de entrada son distintas formas de medir la distancia entre el precio actual y su historia. Las variables se describen a continuación:

- Las primeras variables de la forma $P_t - P_{t-s}$, donde $s \in (1, 3, 5, 7, 10, 20, 30)$, representan el cambio del precio con respecto al precio de s minutos atrás.
- La función $k(P_t, j)$ es una función de suavización exponencial “Kernel” que pondera por el monto de cada transacción y le da más peso a las transacciones más recientes.

Entre menor sea el valor de j , menor será el peso asignado a las transacciones más antiguas. De esta forma, las variables $P_t - k(P_t, j)$ representan el cambio del precio actual con respecto a la suavización exponencial ponderada por monto transado de j minutos atrás (su tendencia); j está medido en minutos, pero, a diferencia de los demás subíndices, puede tomar valores continuos. Los valores utilizados fueron (,03, 0,1, 0,3, 0,7, 1, 6, 10, 20).

- $Var(P_t, P_{t-\tau})$ representa la varianza del precio de las transacciones que han ocurrido τ minutos hacia atrás. Nótese que se toma un valor de τ igual intervalo de pronóstico de la Ecuación 7. De nuevo, éste es un parámetro que se podría optimizar en trabajos futuros.
- Por último, $Sum(q_t, q_{t-\tau})$ representa el volumen total operado de las transacciones que han ocurrido τ minutos hacia atrás.

Durante la investigación se observó que los kernel de suavizamiento son una fuente de información de gran riqueza para los modelos. Lo et al. (2000) utilizan un kernel de suavizamiento exponencial (sin ponderar por monto transado) para evaluar el desempeño del Análisis Técnico y encuentran resultados similares: el kernel de suavizamiento se adapta bastante bien a los datos financieros.

En la presente investigación se utilizó un kernel exponencial ponderado por monto de transacción expresado por la Ecuación (10).⁵

$$k(P_t, j) = \frac{\sum_{u=1}^t (w_{t-u} * N_{t-u} * P_{t-u})}{\sum_{u=1}^t (w_{t-u} * N_{t-u})} \quad \forall u \leq t \quad (8)$$

$$(9)$$

$$w_{t-u} = \frac{e^{-\frac{|t-u|}{j}}}{j}, \quad (10)$$

donde N_t representa el nocional de la transacción ocurrida en el periodo t y $|x|$ representa el valor absoluto de x . Todos los subíndices están medidos en minutos y toman valores continuos; la llegada de transacciones no ocurre en tiempo discreto. Es de notar que por lo general se utiliza la Ecuación (10) $\forall u$; sin embargo, dado que se quiere realizar un backtest, no es posible incluir información que no se tenga hasta el periodo t . Por tal motivo, cualquier $u > t$ queda descartado y el Kernel solo es utilizado hasta t .

En la literatura se observa que el valor de j (conocido en la literatura como *bandwidth*) debe ser optimizado. Este representa el espacio de tiempo a ponderar; entre mayor sea el valor de j , mayor será el peso otorgado a las observaciones más antiguas. Lo et al. (2000) exponen un proceso de optimización para el ancho de banda llamado cross-validation (distinto al concepto usado en *machine learning*). Este consiste en estimar, para distintos j , excluyendo la observación t ($u \neq t$), el valor equivalente de

⁵Dado que los precios llegan en tiempos no discretos, los kernels solamente se estimaron cada vez que una transacción ocurría. Tras ello, su valor se dejó constante hasta el arribo de una nueva transacción.

$k(P_t, j)$. Al final se minimiza el error cuadrático de $P_t - k(P_t, j)$. Los autores encuentran que dicho proceso de optimización resulta en un ancho de banda muy superior al deseado y que debe ser dividido entre 3 (empíricamente observan esta característica). El proceso de cross-validation se realizó sobre 300 días aleatorios de la muestra del mercado de TES, y a diferencia de lo encontrado por los anteriores autores, se obtuvo un ancho de banda muy bajo (menos de un minuto). Esto responde a las características ya mencionadas del mercado analizado: largos periodos donde no se observan transacciones, seguidos por periodos de alta transaccionalidad. Lo anterior genera que la mejor predicción de P_t se consiga al ponderar periodos muy pequeños de tiempo por medio de un $j < 1$.

Se corrió el backtest utilizando el ancho de banda obtenido por la anterior metodología de optimización; sin embargo, se obtuvo un desempeño inferior al observado al incluir varios anchos de banda como distintas variables explicativas. Con esto se concluye que los distintos valores de j permiten a los modelos diferenciar tendencias de distintos plazos sobre el precio del activo. Esta información es discernida por el modelo estadístico ofreciendo un mayor poder predictivo. De igual forma se probó el kernel Epanechnikov y el kernel Gaussiano de las Ecuaciones (11) y (12) respectivamente, sin encontrar un mejor desempeño en el backtest:

$$w_{t-u} = \frac{3}{4} * \left(1 - \left(\frac{t-u}{j}\right)^2\right) * \mathcal{I}_{\{|u|/j < 1\}} \quad (11)$$

$$w_{t-u} = \frac{1}{\sqrt{2\pi} * j} * e^{-\frac{(t-u)^2}{2j^2}}. \quad (12)$$

Adicional a las variables de entrada, es necesario especificar la frecuencia de calibración del modelo y la cantidad de observaciones utilizadas para calibrarlo. Para poder realizar un backtest de forma precisa, es necesario garantizar que la estrategia de *trading* no utilice información que no se tendría en el momento t . Por ello, de forma estándar, cada modelo se calibra mensualmente exclusivamente con información que se conocería al momento de calibración. Sin embargo, la cantidad de información utilizada (número de meses atrás m) para calibrar el modelo variará dependiendo de su desempeño en cada una de las herramientas estadísticas.

4.2. Herramientas estadísticas de predicción

Tras haber descrito las variables de entrada de los modelos, a continuación se presentan las herramientas estadísticas utilizadas (Logit, Random Forest y SVM) y las estrategias de *trading* que se diseñan a partir de ellas.

4.2.1. Logit

Para el modelo Logit Multinomial el mejor resultado fue obtenido al incluir todas las variables mencionadas anteriormente (Sección 4.1) excepto $Sum(q_t, q_{t-\tau})$. Por su parte, el valor óptimo de τ es igual a 10 y se utilizan 6 meses de historia para calibrar el modelo ($m = 6$).

La variable de salida de $f(\phi_t)$ es una variable categórica, la cual se divide en 5 posibles categorías: “S”, el precio va a ser estable; “U” el precio va a subir; “RU” el precio va a subir por encima del percentil 85⁶ del histórico del mes anterior, “D” el precio va a bajar; “RD” el precio va a caer por debajo del negativo del percentil 85 del histórico del mes anterior. De esta forma, la estrategia a implementar es la siguiente. Si

$$f^{10}(\phi_t) = RU, \quad (13)$$

se compra el activo. Se analiza el mercado cada minuto y se pronostica de nuevo $f^{10}(\phi_t)$. Así, se retiene el activo hasta que

$$f^{10}(\phi_t) = S, D \text{ o } RD. \quad (14)$$

La estrategia para la posición en corto

$$f^{10}(\phi_t) = RD \quad (15)$$

es análoga. Como es de esperar, los resultados del modelo Logit, por ser basados en una variable categórica, presentan el backtest con menor poder predictivo.⁷

4.2.2. Random Forest

Random Forest es una metodología de aprendizaje de máquinas. Debido a que es un método de predicción poco conocido, en el Anexo A se ofrece una breve descripción de la metodología. Para este modelo se encontró que las mejores variables para predecir son las observadas en la siguiente Ecuación:

$$f^{10}(\phi_t) = f^{10}(P_t - P_{t-s}, P_t - k(P_t, j), Var(P_t, P_{t-10})). \quad (16)$$

Por su parte, el τ óptimo es igual a 10 minutos, el número de meses para calibrar el

⁶De forma más precisa, el percentil 85 corresponde al histórico empírico de los cambios en precios en lapsos iguales a τ minutos del mes inmediatamente anterior al mes que se va a pronosticar.

⁷Originalmente el SVM también predecía una variable categórica. Debido a esto, uno de los modelos de comparación era el modelo logit. No obstante, se encontró que el SVM tenía un mejor desempeño si la variable de pronóstico se trataba como continua.

modelo es igual a 4 meses y se generaron 1.000 árboles aleatorios. Dado que $f^{10}(\phi_t)$ es una variable continua para RF, la estrategia de *trading* se define de la siguiente forma: Sí $f^{10}(\phi_t)$ es superior al percentil 99 de las predicciones realizadas sobre el último mes de calibración, se compra el activo. Se revisa el mercado cada minuto y se retiene hasta que $f^{10}(\phi_t)$ sea menor o igual a 0. Por el contrario, si $f^{10}(\phi_t)$ es inferior al negativo del percentil 99 de las predicciones realizadas sobre el último mes de calibración se toma una posición en corto. Esta se mantiene hasta que $f^{10}(\phi_t)$ sea mayor o igual a 0.

4.2.3. Support Vectors Machine

Al igual que en el caso de Random Forest, en el Anexo B se puede observar una breve descripción de la metodología de SVM. Para dicho modelo, las variables a utilizar son las observadas en la siguiente Ecuación:

$$f^2(\phi_t) = f^2(P_t - P_{t-s}, P_t - k(P_t, j)). \quad (17)$$

De forma óptima τ es igual a 2; para este modelo se utilizaron los últimos 6 meses para realizar la calibración ($m = 6$). Para el SVM, se utilizó un Kernel Radial con parámetros $c = \Gamma = 2^{-6}$. Dado que $f^2(\phi_t)$ es una variable continua, la estrategia de *trading* es la siguiente: Sí $f^2(\phi_t)$ es superior al percentil 98.5 de las predicciones realizadas sobre el último mes de calibración, se compra el activo. Se revisa el mercado cada minuto y se retiene el activo hasta que $f^2(\phi_t)$ sea menor o igual a 0. Por el contrario, si $f^2(\phi_t)$ es inferior al negativo del percentil 98.5 de las predicciones realizadas sobre el último mes de calibración, se toma una posición en corto. Esta se mantiene hasta que $f^2(\phi_t)$ sea mayor o igual a 0.

4.3. Equivalente de certeza

Con el fin de realizar una comparación más acertada de los modelos, se decidió utilizar el Equivalente de Certeza correspondiente a la distribución de ganancias de cada uno de los modelos. Para calcular el Equivalente de Certeza se utiliza una función de utilidad HARA de la siguiente forma:

$$U(x) = -(x + 100)^{-0,4}, \quad (18)$$

donde x está medido en puntos básicos. Así, la aversión al riesgo es una función decreciente igual a:

$$A(x) = -\frac{U''(x)}{U'(x)} = \frac{1,4}{x + 100}. \quad (19)$$

Esto significa que la aversión al riesgo es inversamente proporcional a las ganancias. En

particular los parámetros son escogidos a priori. Sin embargo, para entender la aversión al riesgo de esta función de utilidad, se puede tener en cuenta que una lotería que paga con 50 % de probabilidad 0 y 50 % de probabilidad 100 puntos básico tiene un equivalente de certeza de 38.075. En otras palabras, una persona con esta función de utilidad sería indiferente entre tener un pago de 38.075 puntos básicos con 100 % de probabilidad y la lotería anteriormente descrita.

Lo anterior se puede observar en la siguiente ecuación:

$$\frac{-(100 + 100)^{-,4} - (100 + 0)^{-,4}}{2} = -(100 + x)^{-,4}, \quad (20)$$

de nuevo, estos valores son escogidos por el Autor y su connotación es únicamente intuitiva.

5. Resultados

En esta sección se muestran los principales resultados de los tres modelos. Para cada uno se presenta un histograma de las ganancias (Anexo C) y un cuadro resumen de los resultados. En los histogramas se pueden observar algunas de las medidas descriptivas del PyG de cada algoritmo, al igual que medidas de riesgo como el VaR y el CVaR. Por su parte, los cuadros contienen la siguiente información: PyG Total, es el número de puntos básicos (PB) ganados; Número de entradas, es el número de veces que se abre y se cierra una posición; PyG Promedio, es el resultante de dividir los dos valores anteriores; Duración de Posiciones, es el tiempo promedio medido en minutos que se tuvieron abiertas las posiciones; E. Certeza, es un PyG promedio ajustado por riesgo (ver Sección 4.3); P. Éxito, es el número de veces que se ganó dinero sobre el total de entradas; PyG|Éxito, es el promedio del PyG dado que se ganó dinero; PyG|Pérdida, es el promedio del PyG dado que el pronóstico fue equivocado; E|P, es igual al número de éxitos sobre el número de pérdidas; por último, PyG EC es el valor del PyG promedio corregido por riesgo (equivalente de certeza) multiplicado por el número de entradas y la duración del bono, menos los costos de transacción⁸ multiplicados por el número de entradas (su valor se encuentra en millones de pesos netos).

Como se había mencionado anteriormente, el modelo Logit es el de menor poder de pronóstico. No obstante, con un PyG corregido por riesgo (PyG EC) de \$210 millones, el PyG después de costos de transacción es positivo. El equivalente de certeza es de 0.16 p.b. y la probabilidad de éxito es 2.2 veces mayor a la de pérdida.

Para el modelo predictivo Random Forest el PyG EC es positivo y superior al del

⁸El costo de transacción de una comisionista de bolsa colombiana en el mercado de TES es de alrededor de \$20,000 por posición. Este es un costo fijo. Debido a esto, se supone que existe un costo total de entrada y salida de \$40,000.

	PyG Total	Número de Entradas	PyG Prom	Duración Posiciones	E. Certeza	P.Éxitos	PyG Éxito	PyG Pérdida	E P	PyG EC
Logit	362.80	2224	0.16	6.50	0.16	0.53	0.69	-0.84	2.20	209.99
RF	425.70	2931	0.15	6.84	0.14	0.52	0.79	-0.83	1.63	237.15
SVM	899.90	3396	0.26	10.03	0.26	0.69	0.73	-1.05	3.03	607.85

Cuadro 1: Estadísticas de los resultados de los algoritmos de *trading* Logit, Random Forest y SVM. Fuente: AFIN y Banco de la República. Cálculos: del Autor.




Figura 4: PyG mensual de cada uno de los algoritmos. Fuente: AFIN y Banco de la República. Cálculos del Autor.

modelo logit (\$237 millones). De igual forma, la probabilidad de éxito es 1.62 veces la probabilidad de pérdida.

Por último, en las figuras del Anexo (C) y en el Cuadro (1) se muestran los resultados del algoritmo de *trading* basado en SVM. Al igual que en el caso del modelo Logit y Random Forest, el PyG EC es positivo, aunque superior a los dos modelos anteriormente mencionados (\$604 millones). Lo mismo sucede con la probabilidad de éxito que es igual a 2.95 veces la probabilidad de pérdida y el equivalente de certeza que es igual a 0.26 p.b.

El PyG mensual neto corregido por riesgo se puede observar en la Figura 4, y en el Anexo D se presentan los detalles mensuales para el modelo de SVM. En ellos se observa que, para el SVM, solo en 6 meses de 52 de muestra, el algoritmo presenta pérdidas netas después de corregir por riesgo. Este valor para el Logit y el RF es de 8 y 10 respectivamente. El valor esperado del PyG mensual corregido por riesgo para el SVM, el RF y el modelo logit sería de \$11.68, \$4.51 y \$4.01 millones de pesos. Como consecuencia de ello, se puede afirmar que sí es posible crear una estrategia de *trading* con retornos esperados positivos y predecir el precio de los TES. De esta forma, se comprueba que el precio de los TES 24's no refleja toda la información disponible y no sigue una caminata

aleatoria, por lo que se rechaza RW2.

5.1. Comparación con otros mercados y activos

Siguiendo la discusión planteada en la sección 2.1.4, a continuación se presenta el Backtest sobre el mercado norteamericano y sobre otras referencias de TES.

5.1.1. SVM: Mercado de bonos de los Estados Unidos

El algoritmo basado en SVM, por ser el de mayor predictibilidad, fue utilizado para predecir el precio del Bono Gubernamental Genérico a 10 años de los Estados Unidos tomado de Bloomberg. Esta herramienta solo permite descargar una cantidad limitada de historia de datos intraday para este activo, por lo que solamente se recuperaron 12 meses de información. De igual forma Bloomberg no ofrece información del volumen transado, por lo que solamente se utilizó el kernel de suavizamiento sin ponderar por monto transado.⁹

Los resultados se presentan en el Cuadro (2). En estos se observa que el nivel de predictibilidad del algoritmo se reduce drásticamente. A pesar de que la probabilidad de éxito es bastante alta con respecto a la probabilidad de pérdida (3.26 veces), el PyG dado éxito es significativamente inferior a lo observado en el mercado de TES. Por su parte, el PyG promedio es de 0.07 pb mientras que en los TES es de 0.26. Las variables de entrada y el valor de τ no son necesariamente las óptimas para el mercado estadounidense; sin embargo, los anteriores resultados son evidencia de que el mercado de TES es más predecible que el mercado norteamericano.

	PyG Total	Número de Entradas	PyG Prom	Duración Posiciones	E. Certeza	P.Éxitos	PyG Éxito	PyG Pérdida	E P
Enero	17.53	202	0.09	2.62	0.09	0.59	0.25	-0.31	2.93
Febrero	39.06	489	0.08	2.99	0.08	0.59	0.25	-0.39	3.44
Marzo	29.14	435	0.07	2.63	0.07	0.56	0.21	-0.34	3.70
Abril	29.41	569	0.05	3.43	0.05	0.49	0.21	-0.30	2.75
Mayo	7.00	119	0.06	3.69	0.06	0.52	0.19	-0.42	5.17
Junio	1.20	15	0.08	2.07	0.08	0.53	0.19	-0.34	8.00
Julio	0.17	25	0.01	3.12	0.01	0.60	0.20	-0.41	2.14
Agosto	-0.52	56	-0.01	3.34	-0.01	0.38	0.19	-0.33	1.50
Septiembre	3.81	79	0.05	4.03	0.05	0.54	0.21	-0.27	2.26
Octubre	9.90	88	0.11	2.95	0.11	0.68	0.20	-0.45	12.00
Total	136.70	2077	0.07	3.08	0.07	0.55	0.22	-0.34	3.26

Cuadro 2: Estadísticas de los resultados del algoritmo de *trading* SVM. Fuente: Bloomberg. Cálculos: del Autor.

⁹De igual forma, se corrió para los 5 años de información de TES el algoritmo sin ponderar por monto y los resultados no cambian significativamente.

5.1.2. Tes 24 relativos a los TES 16

Para dar completitud a la investigación, el algoritmo de SVM fue utilizado para predecir el precio de los TES con vencimiento 2016 y la diferencia de la tasa entre los 24 y los 16. En el Cuadro (3) se observan el desempeño del algoritmo y se concluye que los resultados son robustos y efectivamente es posible predecir el precio de los TES a futuro. Esto se concluye al obtener equivalentes de certeza de 0.32 y 0.58 puntos básicos.

Es necesario reconocer que realizar un Backtest sobre los spreads es un ejercicio principalmente teórico. En la practica se dificulta comprar y vender dos activos distintos al mismo tiempo teniendo en cuenta el diferencial de liquidez entre las dos referencias.

	PyG Total	Número de Entradas	PyG Prom	Duración Posiciones	E. Certeza	P.Éxitos	PyG Éxito	PyG Pérdida	E P
16's	465.40	1380	0.34	22.91	0.32	0.66	1.03	-1.48	2.82
24's-16's	2291.20	3929	0.58	9.25	0.58	0.81	0.87	-0.85	5.45

Cuadro 3: Estadísticas de los resultados del algoritmo de *trading* SVM para los TES 16 y la diferencia entre los 24's y 16's. Fuente: AFIN y Banco de la República. Cálculos: del Autor

6. Conclusiones

En este documento se analizó el cumplimiento de la hipótesis de caminata aleatoria para el principal mercado financiero colombiano, el de deuda pública, en particular su activo más líquido, los TES 24. La investigación desarrollada se enfocó en los test de forma débil, que consisten en comprobar si el precio del activo siempre refleja completamente toda la información disponible. Los principales resultados encontrados muestran que para el caso de los TES colombianos esto no se cumple. Dicha comprobación es realizada por medio de una estrategia de *trading* que, utilizando un modelo de predicción estadístico, anticipa el movimiento del precio de los TES. Al final, por medio de un Backtest, se encuentra que los retornos esperados de la estrategia de *trading* son positivos y superiores a los costos de transacción. Debido a esto, se puede afirmar que el precio de los TES 24's y sus retornos no siguen una caminata aleatoria.

En los resultados de los Backtest se observa que el desempeño del modelo se preserva en distintos periodos el tiempo y casi no se observan pérdidas acumuladas por mes. De igual forma, los resultados se mantienen utilizando otras referencias de TES y la diferencia entre el precio de dos referencias (análisis relativo). Por otra parte, al implementar el algoritmo en el mercado estadounidense se encuentran retornos esperados positivos aunque sustancialmente inferiores a los presentados en el mercado de TES. Como ya se mencionó, debido a que en la literatura no hay una definición que determine hasta qué punto un mercado que se pueda predecir se sigue considerando como eficiente, los anteriores resultados no son suficientes para determinar ineficiencia en el mercado de

TES. No obstante, se considera que el resultado de la investigación abre la oportunidad para estudiar la eficiencia del mercado de TES en trabajos futuros. Por tal motivo, para futuras investigaciones se espera desarrollar un modelo que defina un *benchmark* que pueda ser utilizado para determinar si la predictibilidad de un mercado (observada en un Backtest) es señal de ineficiencia.

Por otra parte, se resalta que el principal valor agregado ofrecido por la investigación es el algoritmo de *trading* desarrollado. Si bien, el fin de este texto tiene como objetivo la comprobación de la hipótesis de caminata aleatoria en un mercado en particular, la metodología desarrollada podría ser utilizada para analizar otros mercados financieros. De igual forma, además de tener aplicaciones académicas, el algoritmo podría ser utilizado como una estrategia de inversión en la vida real.

Con respecto a la metodología desarrollada, los trabajos expuestos en la revisión de literatura rechazan la hipótesis de caminata aleatoria por medio de pruebas estadísticas sobre muestra. A diferencia de estos estudios, el presente documento demuestra que, para el mercado colombiano, la predictibilidad observada dentro de muestra puede ser utilizada para predecir el precio fuera de muestra. De esta forma, se considera que los Backtest son una metodología más robusta dado que permiten determinar si lo observado en muestra puede ser efectivamente utilizado para generar una estrategia con retornos esperados positivos.

Por otro lado, existen posibilidades de optimizar los parámetros utilizados como los *bandwidth*, el periodo de calibración y el número de minutos a predecir (τ) al igual que la selección de variables. De ello, se esperaría mejorar aun más el poder de pronóstico de los modelos.

Finalmente, debido a que el mercado presenta señales de ineficiencia en el sentido débil (rechazo de la hipótesis de caminata aleatoria), se esperaría que también las presente en el sentido semifuerte y fuerte. A causa de ello, trabajos futuros incluirán test de tipo semifuerte y fuerte para el mercado de TES. Posiblemente de esta forma se logre determinar si el mercado es eficiente o no. Se esperaría que ésto fuera un llamado para las autoridades regulatorias de promover el mercado financiero colombiano.

7. Bibliografía

Alexander, S. (1961) Price Movements in Speculative Markets: Trends or Random Walks. *Industrial Management Review*. 76. pp 7-26.

Alexander, S. (1964) Price Movements in Speculative Markets: Trends or Random Walks. *The random Character of Stock Markets Prices*. MIT Press.

Campbell, J. Lo, A. MacKinlay, G. (1997). *The Econometrics of Financial Markets*. Princeton University Press. New Jersey.

Chordia, T., Roll, R., Subrahmanyamb, A. (2004). Evidence on the Speed of Convergence to Market Efficiency.

Chordia, T., Roll, R., Subrahmanyamb, A. (2008). Liquidity and market efficiency. *Journal of Financial Economics*.

Dacorogna, M. Gençay, R. Müller, U. Olsen, R. Pictet, O. (2001) *An introduction to High-Frequency Finance*. Academic Press.

Fama, E. (1965). The Behavior of Stock Market Prices. *Journal of Business*. 38. pp 34-105.

Kendal, M. (1953). The analysis of Economic time-series. Part 1: Prices. *Journal of the Royal Statistical Society*. 96.

Fama, E. Blume (1966) Filter Rules and Stock Market Trading Profits. *Journal of Business*. 39.

Fama, E. (1970). Efficient Capital Markets: A Review of Theory and Empirical Work. *The Journal of Finance*, Vol. 25, No. 2, Papers and Proceedings of the Twenty-Eighth Annual Meeting of the American Finance Association New York. 25. pp 383-417.

Farmer J. Lo A. (1999). *Frontiers of finance: Evolution and efficient markets*. This paper is a summary of a session presented at the tenth annual symposium on Frontiers of Science, held November 19–21, 1998, at the Arnold and Mabel Beckman Center of the National Academies of Sciences and Engineering in Irvine, CA.

Hautsch, N. (2012). *Econometrics of Financial High-Frequency Data*. Springer. Heidelberg Dordrecht London New York.

Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference and Prediction*. (Segunda ed.). Springer.

Hodrea R. (2015). An intraday analysis of the market efficiency-liquidity relationship: the case of BVB stock exchange. *Procedia Economics and Finance*. 32. pp 24-25.

James, G., Witten, D., & Hastie, T. (2013). *Introduction to Statistical Learning with*

Applications in R. Springer Heidelberg Dordrecht London New York.

Lo A., Mamaysky H., Wang J. (1988). Stock Market Prices do not Follow Random Walks. Review of Financial Studies.

Lo A., Mamaysky H., Wang J. (2000). Foundations of Technical Analysis: Computational Algorithms, Statistical Inference, and Empirical Implementation. The Journal of Finance. 4. pp 1705-1765.

Lo A., MacKinlay G (1999). A Non-Random Walk Down Wall Street. Princeton University Press.

Moore, A. (1962). A Statistical Analysis of Common Stock Prices. PhD Tesis. Universidad de Chicago.

Ojeda, C., Castaño, E. (2014). Prueba de Eficiencia Débil en el Mercado Accionario Colombiano. Universidad de Medellin. Semestre Económico. 17. pp 13-42.

Roll, R. (1984). A Simple Implicit Measure of the Effective Bid-Ask Spread in an Efficient Market. The Journal of Finance, 39, pp 1127-1139.

Rosales, R., Perdomo, J., Morales, C., & Urrego, J. (2013). Fundamentos de Econometría Intermedia: Teoría y Aplicaciones. Bogotá: Ediciones Uniandes.

Trujillo (2015). Trading algorítmico: un análisis para el mercado financiero colombiano. Tesis de Pregrado Universidad de los Andes.

Worthington, A., Higgs, H. (2003). Tests of Random Walks and Market Efficiency in Latin American Stock Markets: An empirical note. School of Economics and Finance, Queensland University of Technology, Brisbane, Australia.

8. Anexos

A. Random Forest

En esta sección se da una breve descripción del método de Random Forest. Al igual que en el caso de SVM no se espera cubrir a profundidad el modelo, no obstante si el lector desea familiarizarse con los métodos puede referenciarse al libro de Hastie, Tibshirani, & Friedman (2009).

De forma general, Random Forest consiste en dividir la muestra en subgrupos dependiendo de las características de cada observación. En la Figura (5) se tiene un ejemplo extraído de Hastie, Tibshirani, & Friedman (2009). En el ejemplo se intenta predecir el salario de un jugador de béisbol dependiendo del número de hits realizados durante su carrera y el número de años que lleva en las grandes ligas. La predicción de cada uno de los jugadores es igual al promedio del salario de los jugadores que cumplen con las divisiones mostradas en la gráfica (mayor y menor a 4.5 años dentro de las grandes ligas y mayor y menor a 117.5 hits).




Figura 5: Explicación teórica de Random Forest. Fuente: Hastie, Tibshirani, & Friedman (2009, capítulo 7).

El nombre de Random Forest proviene de la representación en forma de árbol, de la división de los datos realizada. Un ejemplo de ello se observa en la Figura (6).

Por su parte, Random hace referencia a que se realizan n divisiones, o árboles, de forma aleatoria y se escoge la mejor división por medio de un estadístico de precisión llamado




Figura 6: Explicación teórica de Random Forest. Fuente: Hastie, Tibshirani, & Friedman (2009, capítulo 7).

curva ROC.

B. SVM

De igual forma, el método de minería de datos SVM es explicado por Hastie, Tibshirani, & Friedman (2009) y James, Witten, & Hastie (2013). En este método se separan las observaciones por medio de hiperplanos en R^n , donde n es el número de variable de entradas que se tienen. El nombre de Support Vectors Machine es consecuencia de que el hiperplano está definido solo por ciertas observaciones llamadas vectores de soporte. En la Figura (7) se observa que el hiperplano está caracterizado por β y β_0 . Para calibrar los parámetros se realiza la minimización de la norma de β o lo que es lo mismo la maximización de M .




Figura 7: Explicación teórica SVM. Fuente: Hastie, T., Tibshirani, R. y J. Hastie. (2009, capítulo 8).

Sin embargo, matemáticamente se puede demostrar que para realizar esta calibración solo se tienen en cuenta las observaciones mal clasificadas y las que tienen una distancia al hiperplano menor a M ; estas observaciones son los vectores de soporte.

Para el caso del algoritmo, la clasificación que se desea hacer correspondería a que si el precio observado dentro de τ minutos es mayor o menor al precio actual (dado los valores de las variables calculadas para el precio actual). Sin embargo, SVM permite, para mayor precisión, que el hiperplano no sea recto. Por ejemplo, este podría ser polinomial o radial. De igual forma, se pueden tener más de una clasificación (arriba, abajo o estable) o se podría tener una variable de salida continua (el precio va a subir x pesos). Tras realizar varias pruebas el mejor modelo resultante fue utilizar un hiperplano radial con variable de salida continua.

C. Histogramas de los principales modelos




Figura 8: Histograma del PyG del algoritmo de *trading* Logit. Fuente: AFIN y Banco de la República. Cálculos: del Autor




Figura 9: Histograma del PyG del algoritmo de *trading* Random Forest. Fuente: AFIN y Banco de la República. Cálculos: del Autor




Figura 10: Histograma del PyG del algoritmo de *trading* SVM. Fuente: AFIN y Banco de la República. Cálculos: del Autor




Figura 11: Histograma del PyG del algoritmo de *trading* SVM para el Mercado de los Estados Unidos. Fuente: Bloomberg. Cálculos: del Autor

D. Resultados mensuales del algoritmo de trading basado en SVM

Resultados 2011

	PyG Total	Número de Entradas	PyG Prom	Duración Posiciones	E. Certeza	P.Éxitos	PyG Éxito	PyG Pérdida	E P	PyG EC
Diciembre	4.50	24.00	0.19	26.38	0.18	0.58	0.84	-0.80	1.56	3.10
Total	4.50	24.00	0.19	26.38	0.18	0.58	0.84	-0.80	1.56	3.10

Resultados 2012

	PyG Total	Número de Entradas	PyG Prom	Duración Posiciones	E. Certeza	P.Éxitos	PyG Éxito	PyG Pérdida	E P	PyG EC
Enero	4.20	38.00	0.11	26.32	0.10	0.63	0.70	-1.04	2.00	2.32
Febrero	-0.70	40.00	-0.02	16.02	-0.03	0.62	0.51	-1.34	2.50	-2.24
Marzo	12.40	40.00	0.31	7.78	0.31	0.72	0.50	-0.33	4.83	9.77
Abril	11.20	37.00	0.30	7.54	0.30	0.81	0.43	-0.27	5.00	8.89
Mayo	8.10	17.00	0.48	7.88	0.48	1.00	0.48		Inf	6.76
Junio	16.20	58.00	0.28	9.31	0.28	0.78	0.44	-0.46	5.62	12.64
Julio	14.40	51.00	0.28	9.78	0.28	0.80	0.46	-0.63	5.86	11.50
Agosto	15.30	67.00	0.23	9.12	0.23	0.78	0.43	-0.51	3.71	11.90
Septiembre	1.40	46.00	0.03	11.35	0.03	0.67	0.39	-0.96	2.82	-0.49
Octubre	3.70	16.00	0.23	6.94	0.23	0.69	0.41	-0.40	5.50	3.03
Noviembre	5.00	75.00	0.07	12.71	0.05	0.68	0.61	-1.74	3.40	1.94
Diciembre	28.40	67.00	0.42	12.33	0.42	0.78	0.70	-0.88	5.78	25.92
Total	119.60	552.00	0.22	11.64	0.21	0.74	0.51	-0.90	4.08	91.95

Resultados 2013

	PyG Total	Número de Entradas	PyG Prom	Duración Posiciones	E. Certeza	P.Éxitos	PyG Éxito	PyG Pérdida	E P	PyG EC
Enero	14.10	89.00	0.16	11.36	0.16	0.70	0.48	-0.63	2.48	11.30
Febrero	8.10	51.00	0.16	14.14	0.16	0.73	0.42	-0.62	3.08	6.72
Marzo	6.70	69.00	0.10	8.81	0.09	0.68	0.46	-1.05	3.36	4.52
Abril	17.30	115.00	0.15	8.09	0.14	0.69	0.58	-0.95	2.63	14.06
Mayo	5.80	115.00	0.05	9.71	0.05	0.57	0.52	-0.76	1.76	1.52
Junio	-0.10	107.00	-0.00	7.46	-0.02	0.58	1.09	-2.04	1.88	-4.37
Julio	47.60	296.00	0.16	7.59	0.15	0.62	0.83	-1.33	2.35	30.75
Agosto	26.70	78.00	0.34	14.55	0.33	0.65	0.92	-0.96	2.43	19.98
Septiembre	18.30	63.00	0.29	6.79	0.29	0.65	0.72	-0.80	2.93	13.37
Octubre	29.20	78.00	0.37	7.91	0.37	0.72	0.77	-0.99	4.00	22.70
Noviembre	45.30	93.00	0.49	7.45	0.48	0.75	0.90	-0.97	3.89	35.33
Diciembre	25.00	36.00	0.69	7.56	0.68	0.83	1.08	-1.50	6.00	20.04
Total	244.00	1190.00	0.21	8.89	0.20	0.66	0.74	-1.12	2.60	175.93

Resultados 2014

	PyG Total	Número de Entradas	PyG Prom	Duración Posiciones	E. Certeza	P.Éxitos	PyG Éxito	PyG Pérdida	E P	PyG EC
Enero	0.70	18.00	0.04	17.50	0.03	0.72	0.72	-1.72	2.60	-0.14
Febrero	11.20	31.00	0.36	7.61	0.36	0.77	0.60	-0.83	6.00	7.91
Marzo	11.30	50.00	0.23	7.06	0.22	0.70	0.78	-1.23	2.69	7.45
Abril	35.30	122.00	0.29	6.69	0.28	0.70	0.77	-1.14	3.19	25.95
Mayo	30.60	87.00	0.35	6.41	0.35	0.75	0.67	-0.85	4.33	23.09
Junio	18.00	40.00	0.45	12.18	0.44	0.80	0.81	-1.32	5.33	13.67
Julio	13.60	49.00	0.28	9.20	0.27	0.65	0.69	-0.78	2.91	9.39
Agosto	31.90	76.00	0.42	10.72	0.42	0.76	0.71	-0.63	3.87	23.23
Septiembre	17.80	59.00	0.30	9.90	0.30	0.78	0.67	-1.09	3.83	12.21
Octubre	19.80	51.00	0.39	9.16	0.39	0.78	0.59	-0.67	6.67	13.99
Noviembre	-7.40	29.00	-0.26	13.03	-0.29	0.66	0.54	-2.21	2.38	-7.19
Diciembre	22.40	36.00	0.62	10.58	0.62	0.67	1.05	-0.90	8.00	16.04
Total	205.20	648.00	0.32	9.01	0.31	0.73	0.72	-1.08	3.79	145.61

Resultados 2015

	PyG Total	Número de Entradas	PyG Prom	Duración Posiciones	E. Certeza	P.Éxitos	PyG Éxito	PyG Pérdida	E P	PyG EC
Enero	27.40	128.00	0.21	10.26	0.21	0.70	0.70	-1.07	2.70	16.46
Febrero	34.50	117.00	0.29	8.47	0.29	0.65	0.79	-0.88	2.62	22.69
Marzo	27.30	81.00	0.34	7.64	0.33	0.69	0.76	-0.79	2.95	17.69
Abril	27.90	68.00	0.41	9.40	0.41	0.71	0.73	-0.71	4.80	18.73
Mayo	14.70	30.00	0.49	9.13	0.49	0.87	0.65	-0.73	8.67	9.90
Junio	13.70	52.00	0.26	11.37	0.26	0.58	0.82	-0.84	2.31	7.98
Julio	-0.80	3.00	-0.27	11.00	-0.27	0.33	0.90	-0.85	0.50	-0.70
Agosto	12.60	50.00	0.25	9.76	0.25	0.74	0.71	-1.24	3.36	6.84
Septiembre	25.10	102.00	0.25	11.88	0.24	0.61	0.93	-0.95	1.82	12.81
Octubre	24.30	57.00	0.43	16.33	0.41	0.72	1.07	-1.49	3.15	14.22
Noviembre	38.70	102.00	0.38	11.52	0.37	0.70	0.84	-0.92	3.09	21.51
Diciembre	17.50	41.00	0.43	10.73	0.42	0.56	1.18	-0.80	1.92	9.55
Total	262.90	831.00	0.32	10.48	0.31	0.67	0.82	-0.96	2.77	157.68

Resultados 2016

	PyG Total	Número de Entradas	PyG Prom	Duración Posiciones	E. Certeza	P.Éxitos	PyG Éxito	PyG Pérdida	E P	PyG EC
Enero	22.00	70.00	0.31	11.07	0.31	0.64	0.96	-1.07	2.25	10.87
Febrero	13.80	24.00	0.57	10.33	0.57	0.75	1.03	-1.20	4.50	7.44
Marzo	27.90	57.00	0.49	15.11	0.46	0.75	1.27	-2.22	3.58	15.28
Total	63.70	151.00	0.42	12.48	0.41	0.70	1.10	-1.46	2.94	33.59

Cuadro 4: Estadísticas de los resultados del algoritmo de *trading* SVM. Fuente: AFIN y Banco de la República. Cálculos: del Autor