

Ejercicios - Análisis de series de tiempo financieras

Educación Continua - Universidad de los Andes

Germán Eduardo González

5 de agosto de 2021

Ensamblando los Componentes

El objetivo de este taller es que los estudiantes usen las herramientas aprendidas durante el curso para pronosticar:

- La inflación en marzo del 2018
- Crecimiento del PIB por el lado de la oferta para el primer trimestre de 2018
- El retorno del índice COLCAP para el primer trimestre de 2018

Considere el modelo general visto en clase que incluye tendencia, estacionalidad, ciclos y dinámicas de varianza

$$y_t = T_t(\beta) + \sum_{i=1}^s \gamma_i D_{it} + \varepsilon_t$$

$$\frac{\Phi(L)}{\Theta(L)} \varepsilon_t = \nu_t$$

$$\Phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$$

$$\Theta(L) = 1 - \theta_1 L - \dots - \theta_q L^q$$

$$\Theta(L) = 1 - \theta_1 L - \dots - \theta_q L^q$$

$$\nu_t \sim WN(O, \sigma_t^2)$$

$$\sigma_t^2 = \omega + \alpha(L) \varepsilon_t^2 + \beta(L) \sigma_t^2$$

1. Pronóstico Colcap

Construya los pronósticos a la luz del modelo anterior, siguiendo los pasos a continuación,

1. **Descargue los datos. Seleccione un periodo de análisis. Justifique el periodo seleccionado**

En primer lugar, es importante aclarar que el pronosticar del retorno del índice Colcap, se puede abordar de múltiples y diversas metodologías. En el caso de este taller, nos concentraremos en dos formas, la primera consiste en pronosticar el valor del Colcap en el siguiente trimestre y a partir de este valor si encontrar los retornos. La segunda forma, consiste directamente en pronosticar los retornos del Colcap a partir de los retornos históricos del índice.

Para este fin se descargo la serie de tiempo del Colcap desde el 15 de enero del 2008 hasta el 16 de marzo del 2018, con una periodicidad diaria. Estos datos fueron descargados desde

la página oficial del Banco de la República. La periodicidad de los datos, inicia con la creación del índice y termina con el último cierre de mercado a la fecha de este documento. Finalmente, la serie de tiempo contiene la fecha, el valor del Colcap, la variación absoluta y la variación porcentual del Colcap.

Por otro lado, respecto al periodo de análisis consideramos que aunque los primeros años del índice se vieron influidos indirectamente por la situación económica del país y de cierta manera la crisis financiera mundial de 2007-2008 estos datos puede enriquecer el estudio en la medida en la que pueden ayudar a explicar los diferentes componentes de la serie. Grosso modo, estos primeros años, podrían ayudar a entender mejor el componente de la tendencia y la posible existencia de un ciclo.

2. Grafique la serie.





En los gráficos anteriores, se puede evidenciar que tanto para la frecuencia diaria y la frecuencia semanal se captura una gran volatilidad y ruido que puede llegar a complicar el

análisis y generar distorsiones en la estacionalidad y el ciclo. Por otro lado, la frecuencia trimestral es demasiado simplificada y pueden perderse dinámicas que enriquecen el análisis y por tanto el pronóstico. Dado lo anterior, se decidió tomar únicamente la frecuencia mensual tanto para el caso de el valor del Colcap como los retornos.

3. Discuta, a la luz de la teoría económica y financiera, cuáles de los componentes son relevantes para incluir en su modelo.

El índice de COLCAP es un índice ponderado que incluye como mínimo las 20 acciones de los 20 emisores más líquidas en la Bolsa de Valores de Colombia. El peso está dado por la capitalización de mercado que se ajusta a través del tiempo. Los emisores históricos principales son cerca de 30 empresas del sector financiero (Banco de Bogotá, Bancolombia, Davivienda, ..), del sector comercial (Grupo Éxito, Nutresa,...) y del sector petrolero y cementero (Ecopetrol y Argos), entre otros. (BanRep, 2018) y (BVC, 2016).

En primer lugar, respecto al componente de la tendencia es importante mencionar que en promedio todas las empresas que componen al Colcap experimentan cambios tecnológicos y cambios en la productividad que generan un aumento en los ingresos y dividendos en el largo plazo, impulsando así el crecimiento del índice,

Por otro lado, se podría pensar que existe un componente estacional en el COLCAP, debido a que el desempeño de una gran parte de empresas que conforman el índice fluctúan dependiendo de periodo de la economía. Este componente se puede ver fuertemente marcado en las empresas del sector comercial, las cuales están sujetas a la estacionalidad del consumo privado. Un ejemplo claro, es en diciembre cuando aumenta la venta de productos en el grupo Éxito.

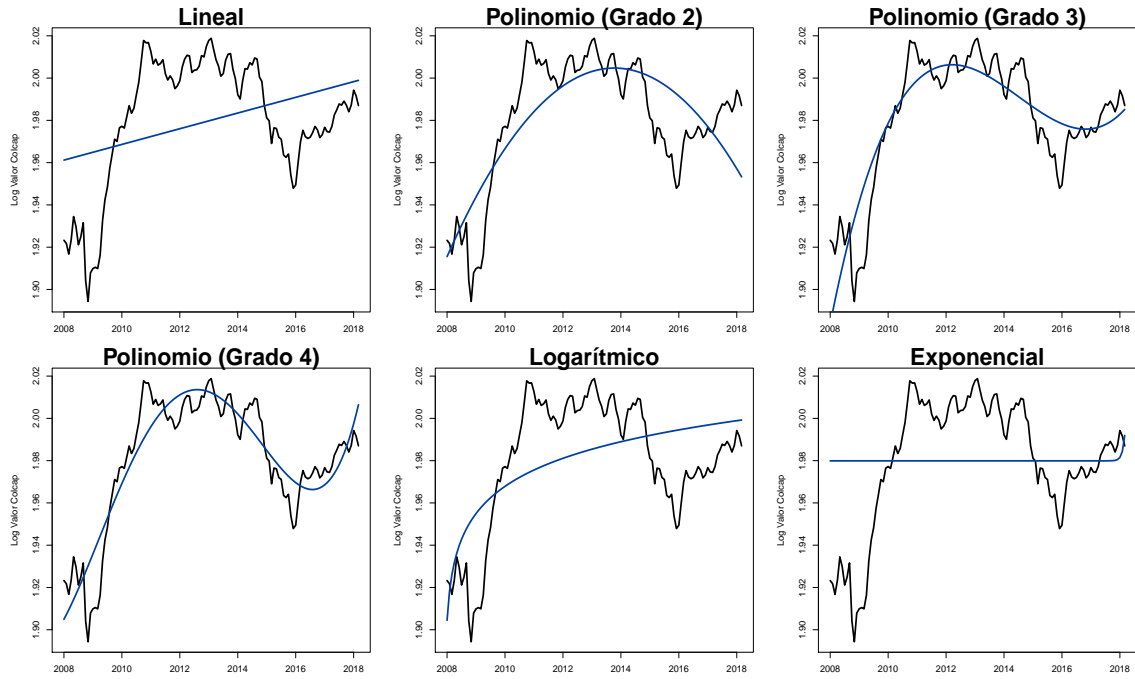
Adicionalmente, estas empresas están muy expuestas al ciclo económico por lo que es importante incluir un componente cíclico en el modelo. A pesar de eso es posible que no sea observable dado que hasta 2008 se creó en el índice y el ciclo económico es bastante amplio.

Concretamente, es porque con el tiempo es de esperar que las empresas que se incluyen en este índice sigan creciendo y por tanto sus acciones sean más valiosas. También por la forma en que está construido el índice, es preponderante la tendencia creciente: En caso de que a una empresa le vaya mal y sus acciones dejen de tranzarse estas no se seguirán incluyendo en el índice y entrará otra que tenga mayor liquidez. Esta última afirmación es verdadera siempre y cuando no se esté en una crisis que afecte en general a la economía y por tanto a todas las empresas que cotizan en bolsa.

4. Estime los componentes de tendencia y estacionalidad (si es relevante). Justifique con estadísticas y criterios de información del modelo estimado.

A partir de aquí se va a trabajar con la serie del logaritmo de Colcap en vez de la serie en niveles para acercar los valores grandes y reducir un poco la volatilidad de la serie.

Tendencia: Valores ajustados Log(Colcap)



Criterios Tendencia: Logaritmo de los valores del Colcap

	Modelo	AIC	BIC	R2_ajustado	Box_Pierce	Ljung_Box	P_valor_f
1	Lineal	-38.27	-29.83	0.12	0.00	0.00	0.00
2	Polinomio (Grado 2)	-134.34	-123.09	0.60	0.00	0.00	0.00
3	Polinomio (Grado 3)	-204.44	-190.38	0.78	0.00	0.00	0.00
4	Polinomio (Grado 4)	-248.01	-231.14	0.84	0.00	0.00	0.00
5	Logarítmico	-76.68	-68.24	0.35	0.00	0.00	0.00
6	Exponencial	-21.94	-13.50	-0.01	0.00	0.00	0.69

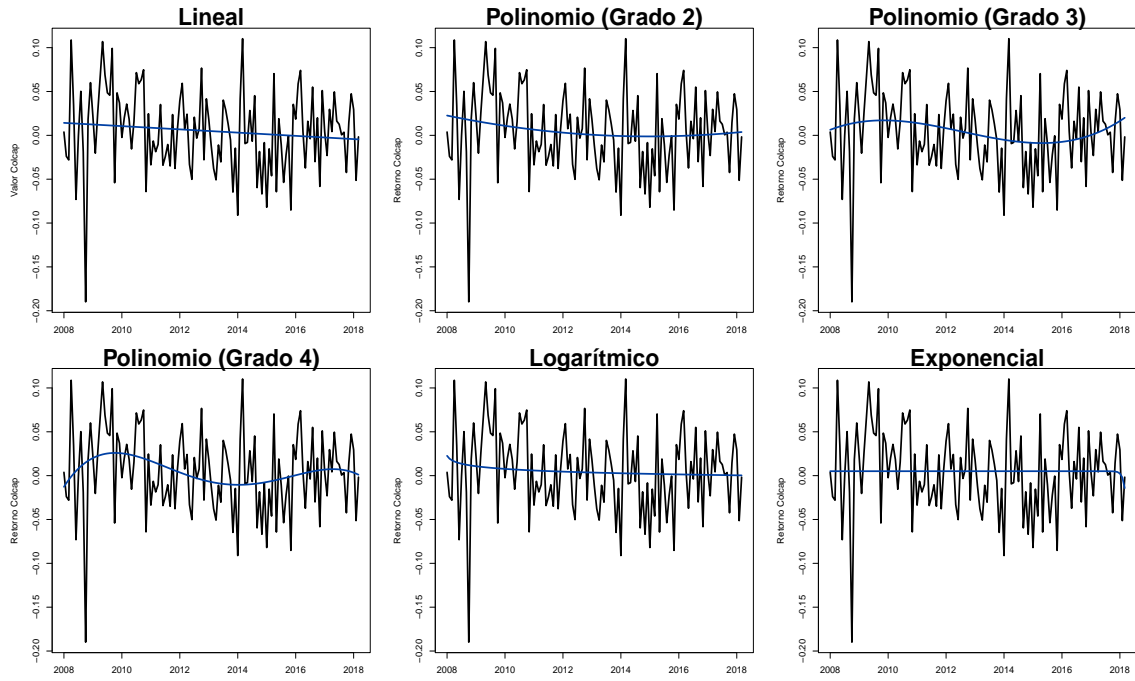
Se puede evidenciar que la serie es claramente no ruido blanco (prueba de Ljung-Box) lo que es un indicio claro de que hace falta incluir más componentes.

Para el caso del logaritmo de los valores del Colcap, existen diferentes tendencias que ajustan de manera plausible a la serie. Sin embargo, para escoger el mejor modelo de tendencia se tienen que tener en cuenta los criterios de información. En la tabla anterior se puede evidenciar que los mejores modelos según los criterios de información son las tendencias no lineales de Grado 2,3 y 4, con los mínimos valores para los AIC y BIC, como también con el R cuadrado ajustado más alto. Dado lo anterior, se toma la tendencia polinomio grado 2 y grado 4, para someterlos a una evaluación y lograr evidenciar cual de los dos estimaciones de la tendencia se comporta mejor.

Dado el criterio de parsimonia se va a analizar también el modelo lineal debido a que puede que los criterios de información sean mejores al elevar el grado del polinomio pero la pérdida de grados de libertad haga menos exacto el pronóstico.

Entonces a partir de aquí se analizará el modelo con tendencia lineal por parsimonia, el modelo cuadrático dado que mejoran los criterios de información respecto al primero y el modelo que toma una tendencia de grado 4 dado que tiene los mejores resultados de criterio de información.

Tendencia: Valores ajustados Retornos del Colcap



Criterios Tendencia: Retornos del Colcap


	Modelo	AIC	BIC	R2_ajustado	Box_Pierce	Ljung_Box	P_valor_f
1	Lineal	-402.28	-393.84	0.01	0.47	0.47	0.19
2	Polinomio (Grado 2)	-401.13	-389.89	0.00	0.52	0.52	0.28
3	Polinomio (Grado 3)	-401.60	-387.54	0.02	0.67	0.67	0.18
4	Polinomio (Grado 4)	-402.46	-385.58	0.03	0.86	0.85	0.11
5	Logarítmico	-401.62	-393.19	0.00	0.44	0.44	0.30
6	Exponencial	-400.74	-392.31	-0.01	0.41	0.40	0.66

Respecto al caso de los retornos mensuales del Colcap, ninguna de las formas funcionales planteadas para la tendencia son significativas con p-valor para la prueba F por encima del 0.05. Adicionalmente, se puede ver que en todos los casos los criterios AIC y BIC son muy cercanos, con un R cuadrado ajustado muy bajo, indicándonos que el cambio en la forma funcional de la tendencia no índice en la capacidad de predicción de la tendencia. Finalmente, con las pruebas de Box Pierce y la de Ljung Box se puede confirmar todo lo mencionado anteriormente, debido a que estas indican que el comportamiento de los residuales del modelo ya son ruido blanco, es decir que es imposible determinar una forma funciona de la tendencia. Dado lo anterior, para el caso de los retornos mensuales del Colcap no se asume ninguna forma funcional de la tendencia.

Tendencia y Estacionalidad: Valores del Colcap

Dado el análisis expuesto anteriormente, se selecciono un modelo de tendencia lineal, de polinomio grado 2 y de polinomio grado 4. Al añadir el componente estacional se ajusta

de la siguiente manera.



Criterios Tendencia y Estacionalidad: Valores del Colcap

	Modelo	AIC	BIC	R2_ajustado	Box_Pierce	Ljung_Box	P_valor_f
1	Lineal	-17.64	21.73	0.99	0.00	0.00	0.00
2	Polinomio (Grado 2)	-113.32	-71.14	0.99	0.00	0.00	0.00
3	Polinomio (Grado 4)	-231.95	-184.15	0.99	0.00	0.00	0.00

En los tres casos, se puede ver que la estacionalidad y la tendencia son significativas con un p-valor cercano a cero. Adicionalmente, en el gráfico anterior se puede ver las líneas ajustadas de tendencia y estacionalidad, no están tan alejadas de los datos históricos. Finalmente, es importante resaltar que luego de limpiar la tendencia y la estacionalidad, los residuales de los modelos ajustados no son ruido blanco. Lo anterior sugiere que existe un componente cíclico.


Criterios Tendencia y Estacionalidad: Retornos Colcap

	Modelo	AIC	BIC	R2_ajustado	Box_Pierce	Ljung_Box	P_valor_f
1	Lineal	-396.18	-356.81	0.04	0.34	0.33	0.17
2	Polinomio (Grado 2)	-395.21	-353.03	0.04	0.38	0.38	0.18
3	Polinomio (Grado 3)	-396.26	-351.26	0.06	0.55	0.55	0.12
4	Polinomio (Grado 4)	-397.47	-349.66	0.07	0.75	0.75	0.08
5	Logaritmico	-395.52	-356.15	0.04	0.31	0.30	0.19
6	Exponencial	-394.79	-355.42	0.03	0.29	0.28	0.22

Debido a que la serie de retornos de Colcap es ruido blanco era de esperarse que no tuviera ni tendencia ni estacionalidad.

5. Construya y grafique la serie desestacionalizada y sin tendencia.





6. Estime el componente cíclico (si es relevante). Justifique con estadísticas y criterios de información el modelo estimado.

Prueba: Ljung-Box

	Modelo	Ljung_Box	Box_Pierce
1	Lineal	0.00	0.00
2	Grado 2	0.00	0.00
3	Grado 4	0.00	0.00
4	Retornos Colcap	0.38	0.39

Se puede evidenciar que luego de eliminar tanto la tendencia como la estacionalidad con las diferentes aproximaciones a la serie de log de Colcap, esta no es ruido blanco. Dado lo anterior, se puede pensar que existe un componente cíclico que esta influyendo en el comportamiento de los errores. Por lo que se debe buscar una aproximación al ciclo, para

lograr eliminar el efecto de este. Por otra parte, la serie de Retornos es directamente ruido blanco por lo que no se puede hacer un análisis de ciclo.

Lineal

Al ajustar un Autoarima a la serie destacionalizada y sin tendencia (lineal) este indica que el mejor modelo posible bajo los criterios AIC y BIC es un ARIMA(1,1,1). Es importante aclarar que el Autoarima plantea una primera diferencia para ajustar la estacionariedad del modelo, sin embargo, al controlar la tendencia y la estacionalidad por variables no es necesario esta diferencia, sino solamente concentrarse en el ciclo. Concretamente, al correr un ARIMA(1,1,1) y controlar por las variables Dummies de estacionalidad y de tendencia, no se llega a la convergencia del modelo. Dado lo anterior, se toma un modelo ARIMA(1,0,1) y se le modifica los tanto los rezagos P y Q, para ver si existe un mejor modelo posible al anteriormente planteado. A continuación se presentan los resultados.

Iteración del AR(P)

	Orden	AIC	BIC
1	ARIMA(0,0,1)	-175.52	-133.34
2	ARIMA(1,0,1)	-434.40	-389.41
3	ARIMA(2,0,1)	-438.76	-390.95
4	ARIMA(3,0,1)	-438.61	-387.99
5	ARIMA(4,0,1)	-436.38	-382.95
6	ARIMA(5,0,1)	-436.66	-380.42

Luego de iterar 5 valores en AR(P) se puede evidenciar que el mejor modelo de todos bajo los criterios AIC y BIC es un ARIMA(2,0,1).

Iteración del MA(Q)

Ahora se prueba iterando bajo los grados Q del MA Luego de iterar 5 valores en MA(Q)

	Orden	AIC	BIC
1	ARIMA(1,0,0)	-418.21	-376.03
2	ARIMA(1,0,1)	-434.40	-389.41
3	ARIMA(1,0,2)	-436.24	-388.43
4	ARIMA(1,0,3)	-437.95	-387.33
5	ARIMA(1,0,4)	-436.52	-383.09
6	ARIMA(1,0,5)	-434.52	-378.28

se puede evidenciar que el mejor modelo de todos bajo los criterios AIC y BIC es un ARIMA(1,0,3). Sin embargo, por principio de parsimonia el ARIMA(2,0,1) es mejor modelo respecto al ARIMA(1,0,3). Adicionalmente, el ARIMA(2,0,1) reporta criterios AIC y BIC mejores que el ARIMA(1,0,3).

Iteración del MA(Q) sobre el AR(2))

	Orden	AIC	BIC
1	ARIMA(2,0,0)	-428.60	-383.60
2	ARIMA(2,0,1)	-438.76	-390.95
3	ARIMA(2,0,2)	-434.76	-384.14
4	ARIMA(2,0,3)	-436.47	-383.04
5	ARIMA(2,0,4)	-435.49	-379.25
6	ARIMA(2,0,5)	-435.37	-376.31

Luego de iterar 5 valores en MA(Q) sobre un AR(2) se puede evidenciar que el mejor modelo de todos bajo los criterios AIC y BIC es un **ARIMA(2,0,1)**.

Modelo de Tendencia Polinomio Grado 2

Al ajustar un Autoarima a la serie destacionalizada y sin tendencia (Grado 2) este indica que el mejor modelo posible bajo los criterios AIC y BIC es un ARIMA(2,0,1).

Iteración del AR(P)

	Orden	AIC	BIC
1	ARIMA(0,0,1)	-262.64	-217.65
2	ARIMA(1,0,1)	-436.16	-388.36
3	ARIMA(2,0,1)	-439.67	-389.05
4	ARIMA(3,0,1)	-439.74	-386.31
5	ARIMA(4,0,1)	-437.92	-381.68
6	ARIMA(5,0,1)	-435.97	-376.91

En la tabla anterior, bajo el criterio AIC y BIC, existen dos mejores modelos. Concretamente, el ARIMA (2,0,1) y el ARIMA (3,0,1) bajo el criterio de parsimonia se escoje el ARIMA (2,0,1) es el mejor modelo, debido que la variación entre los modelos es muy pequeña y el ARIMA (2,0,1) requiere menos parametros de estimación.

Iteración del MA(Q)

	Orden	AIC	BIC
1	ARIMA(2,0,0)	-430.36	-382.55
2	ARIMA(2,0,1)	-439.67	-389.05
3	ARIMA(2,0,2)	-439.54	-386.11
4	ARIMA(2,0,3)	-437.58	-381.34
5	ARIMA(2,0,4)	-437.51	-378.45
6	ARIMA(2,0,5)	-434.18	-372.31

Luego de iterar 5 valores en MA(Q) se puede evidenciar que el mejor modelo de todos bajo los criterios AIC y BIC es un ARIMA(2,0,1). Finalmente, el mejor modelo para el caso de tendencia de grado dos es un ARIMA(2,0,1).

Modelo de Tendencia Polinomio Grado 4

Al ajustar un Autoarima a la serie destacionalizada y sin tendencia (Grado 4) este indica que el mejor modelo posible bajo los criterios AIC y BIC es un ARIMA(1,0,3).

Iteración del AR(P)

	Orden	AIC	BIC
1	ARIMA(0,0,3)	-425.06	-368.81
2	ARIMA(1,0,3)	-445.44	-386.39
3	ARIMA(2,0,3)	-444.11	-382.24
4	ARIMA(3,0,3)	-443.11	-378.43
5	ARIMA(4,0,3)	-454.92	-387.43
6	ARIMA(5,0,3)	-445.06	-374.75

Luego de iterar 5 valores en AR(P) se puede evidenciar que el mejor modelo de todos bajo los criterios AIC y BIC es un ARIMA(4,0,3). En la anterior tabla se puede evidenciar que el criterio AIC mejora infimamente a la medida que aumenta el orden del P. Sin embargo, bajo el criterio de parsimonia se puede afirmar que el mejor modelo es ARIMA(1,0,3), debido a que con menos parametros se puede alcanzar un nivel de los criterios relativamente cercano al aumentar los parametros.

Iteración del MA(Q)

	Orden	AIC	BIC
1	ARIMA(1,0,0)	-425.74	-375.12
2	ARIMA(1,0,1)	-442.98	-389.54
3	ARIMA(1,0,2)	-443.90	-387.66
4	ARIMA(1,0,3)	-445.44	-386.39
5	ARIMA(1,0,4)	-444.65	-382.78
6	ARIMA(1,0,5)	-444.56	-379.88

Luego de iterar 5 valores en MA(P) se puede evidenciar que el mejor modelo de todos bajo los criterios AIC y BIC es un ARIMA(1,0,3). Finalmente, el mejor modelo para el caso de tendencia de grado cuatro es un **ARIMA(1,0,3)**.

Resumen


Modelo	Tendencia	AIC	BIC
Lineal	ARIMA(2,0,1)	-438.76	-390.95
Grado 2	ARIMA(2,0,1)	-439.67	-389.05
Grado 4	ARIMA(1,0,3)	-445.44	-386.39

Modelo para Retornos del Colcap


Al ajustar un Autoarima a la serie de los Retornos del Colcap este indica que el mejor modelo posible bajo los criterios AIC y BIC es un ARIMA(0,0,0). Lo anterior sucede, debido a que la serie es ruido blanco, es decir que los retornos del Colcap, no tiene tendencia, estacionalidad, ni ciclo. Dado lo anterior, el mejor modelo que se adapta a este tipo de series es la media incondicional, que al ser ruido blanco es cero o cercana a esta (0.004816778).

7. Construya y grafique la serie de residuales. Justifique que se trata de ruido blanco.


Tendencia lineal:




Polinomio Grado 2:



Polinomio Grado 4:



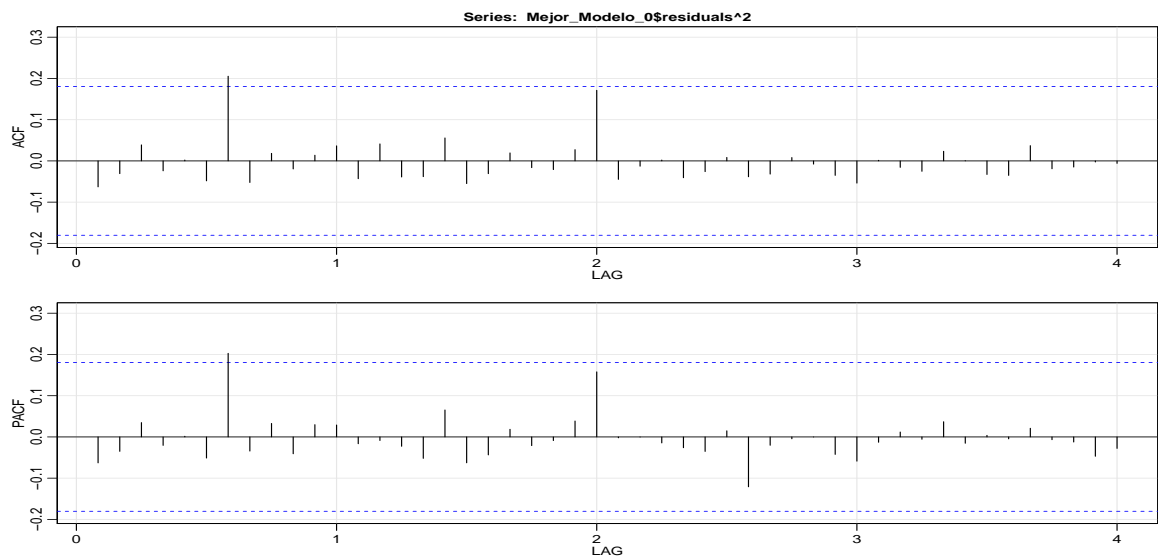
Retornos del COLCAP:**Pruebas de ruido blanco**

	Modelo	Ljung Box	Box Pierce
1	Lineal	0.41	0.42
2	Grado 2	0.38	0.39
3	Grado 4	0.84	0.85
4	Retornos Colcap	0.38	0.39


Tanto en las gráficas como en la tabla anterior se puede ver que en todos los casos los errores son ruido blanco.

8. Estime la dinámica de la varianza (si es relevante).


En este punto, es importante ver si existe una correlación serial en los errores, o si existe clusters de volatilidad que generen ruido dentro de los modelos estimados anteriormente. Si la varianza de los errores muestra cierto comportamiento se puede mejorar el pronóstico al identificarla. Para esto, estimamos los residuales al cuadrado y analizamos las ACF y la PACF.

Lineal: ACF y PACF (Errores al cuadrado)

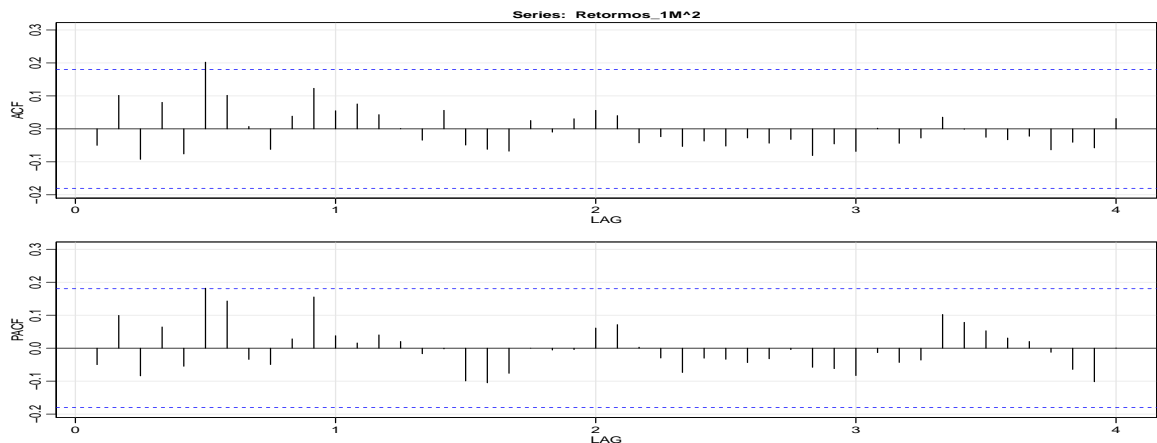
Grado 2: ACF y PACF (Errores al cuadrado)



Grado 4: ACF y PACF (Errores al cuadrado)



Retornos del Colcap: ACF y PACF (Errores al cuadrado)



Todos los modelos del logaritmo del índice de Colcap y de los retornos de Colcap resultan tener un comportamiento igual de los residuales al cuadrado. Se puede ver que los residuales al cuadrado de los modelos, se encuentran dentro de las bandas, y no se evidencian clusters de volatilidad. Esto permite concluir que no es pertinente modelar con un GARCH ninguna de las series. Las gráficas del punto anterior servían como una primera aproximación, en estas no se evidenciaba un comportamiento particular de los residuales lo que es congruente con los resultados de las ACF y PACF de los residuales al cuadrado.

9. Justifique que su modelo captura todas las dinámicas de varianza relevantes. Realice las pruebas necesarias.

Como se evidenció en el numeral anterior, los modelos propuestos no tienen ninguna dinámica de varianza. Dado esto no consideramos pertinente estimar un GARCH y por tanto no vamos a hacer pruebas sobre sus coeficientes.

10. Documente pruebas de normalidad, u otras relevantes para justificar los supuestos de su modelo.

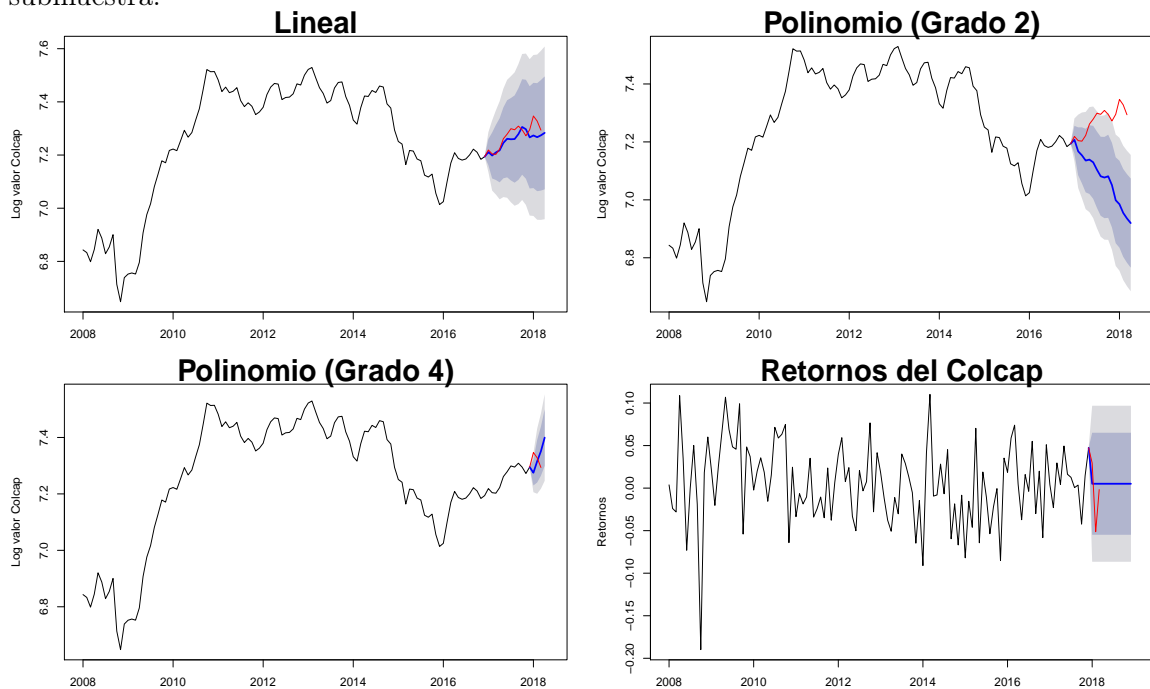
Pruebas

	Modelo	Media	Desviacion	Curtosis	Skewness	JV_pvalor	L_B
1	Lineal	0.00	0.03	4.29	-0.93	0.00	0.41
2	Grado 2	0.00	0.03	5.26	-1.11	0.00	0.38
3	Grado 4	0.00	0.03	6.29	-1.32	0.00	0.84
4	Retornos Colcap	0.00	0.05	1.45	-0.45	0.00	0.38

Interpretació: La prueba de Jarque Bera permite concluir que se rechaza la hipótesis nula de que los errores tengan distribución normal. Sin embargo la prueba de Ljung-Box permite saber que sí se comportan como ruido blanco. Esto implica que al realizar los intervalos y el pronóstico de densidad no se puede asumir una distribución normal a la hora de hacer la simulación.

Pronostico dentro de la muestra:

Además de las pruebas anteriormente realizadas, la realización de un pronóstico dentro de la muestra nos ayuda a ver el verdadero ajuste del modelo, la tendencia y la estacionalidad a los datos ya realizados. Concretamente, la muestra se dividió en dos submuestras, la primera contiene datos desde enero del 2007 hasta diciembre del 2016 y la segunda contiene datos desde enero del 2017 hasta marzo del 2018. Dada las muestras anteriores, se corrieron los modelos con la primera muestra y se pronostico 12 pasos adelante, para luego comparar el pronóstico con los verdaderos datos de la segunda submuestra.




Al realizar el pronóstico dentro de la muestra se puede evidenciar que el modelo que mejor se ajusta a los datos de la muestra es el modelo lineal. Aunque el modelo de tendencia de grado 2 y grado 4 tengan unos mejores criterios de información, estas formas funcionales son explosivas, desviando el pronóstico de manera radical. Finalmente, respecto a los retornos del Colcap como habíamos mencionado anteriormente, el mejor modelo al ser ruido blanco es la media igual a cero, la cual no se ajusta correctamente al modelo dentro de la muestra. Finalmente, siguiendo el principio de parsimonia y dado que el mejor modelo que se ajusta dentro de la muestra es el lineal, solamente tomaremos este.

11. Construya el pronóstico puntual, el intervalo de 95 por ciento de confianza y la densidad.


Recapitulando, es importante aclarar que el objetivo de este ejercicio es pronóstico de los retornos trimestrales del Colcap durante el tercer trimestre. Sin embargo, al intentar pronosticar los retornos directamente se logro encontrar que el mejor pronóstico posible era la media incondicional que es igual a cero. Dado lo anterior, se desarrollo como metodología alterna el pronóstico de los valores logaritmicos mensuales del COLCAP, para lograr estimar los valores del Colcap y a estos si sacarle los retornos trimestrales y así lograr un mejor pronóstico que el ingenuo. Adicionalmente, dado que los valores de enero y febrero del 2018 son conocidos, el pronóstico por fuera de la muestra se hizo a partir de marzo, ignorando los días conocidos de marzo. Partiendo de lo anterior, mostramos el mejor pronóstico lineal en logaritmo, posteriormente le aplicamos la transformación exponencial para volver a niveles y finalmente, tomamos el punto pronosticado y lo agregamos a los datos conocidos de la muestra para encontrar los retornos trimestrales.

Pronostico lineal al logaritmo de los valores del Colcap



En el gráfico anterior se presenta, el pronóstico para 12 pasos adelante, del logaritmo del valor del Colcap.


Densidad: Pronóstico lineal al logaritmo de los valores del Colcap



En el gráfico anterior se presenta, el pronóstico puntal para el valor del Colcap en todo el mes de marzo (log) , la densidad y los intervalos de confianza. Como se mostró anteriormente, al no cumplirse test de Jarque Bera, no se puede asumir que los errores se distribuyen como normales. Dado lo anterior, se planteó 10000 simulaciones de las perturbaciones sin una distribución normal, es decir que se cogió muestras con reemplazo de los residuales. El punto pronosticado en logaritmo es 7.314743 para marzo. Los intervalos de confianza para el 95 % es 7.247060 (2.5 %) y 7.374806 (97.5 %)


Pronostico lineal de los valores del Colcap

Dado que el modelo original se realizó una transformación logarítmica, para volver a los niveles del Colcap, se realizó una transformación exponencial. A continuación se presentan los resultados.




En el gráfico anterior se presenta, el pronóstico para 12 pasos adelante, del valor del Colcap.

Densidad: Pronostico lineal de los valores del Colcap



En el gráfico anterior se presenta, el pronostico puntal para el valor del Colcap en todo el mes de marzo (niveles) , la densidad y los intervalos de confianza. Como se mostró anteriormente, al no cumplirse test de Jarque Bera, no se puede asumir que los errores se distribuyen como normales. Dado lo anterior, se planteó 10000 simulaciones de las perturbaciones sin una distribución normal, es decir que se cogió muestras con reemplazo de los residuales. El punto pronosticado en niveles es 1502.286 para marzo. Los intervalos de confianza para el 95 % es 1404.180 (2.5 %) y 1595.282 (97.5 %).

Pronostico: Retornos primer trimestre del 2018



Finalmente, luego de incluir el punto pronosticado para el valor del Colcap en marzo a la serie mensual y calcular los retornos trimestrales del Colcap, nuestro mejor pronostico es un retorno del 0.019798948 para el primer trimestre del 2018.

2. Inflación Marzo 2018

Construya los pronósticos a la luz del modelo anterior, siguiendo los pasos a continuación.


1. Descargue los datos. Seleccione un periodo de análisis. Justifique el periodo seleccionado

En primer lugar, se descargo la serie de tiempo que publica el DANE para los años desde el 2003 hasta febrero del 2018. La serie tiene una periodicidad mensual, dada la forma en la que se reporta. Así mismo, se usa el dato para la variación mensual del cambio porcentual del IPC porque se busca pronosticar la inflación de marzo del 2018.


En segundo lugar, hay dos razones que justifican el periodo seleccionado. Por un lado, se busca que sea después de 1999, año en el cual la inflación para Colombia toma valores de un sólo dígito, que se ha mantenido en el tiempo hasta la actualidad logrando un comportamiento autoregresivo importante que se puede afectar si se usan datos más antiguos. Por otro lado, el IPC tiene algunos retos metodológicos debido a la forma en la que se fija la canasta básica de referencia. En esa dirección, entre octubre de 2006 y septiembre de 2007, el DANE a partir de la Gran Encuesta Integrada de Hogares logró determinar algunos cambios en los hábitos de consumo y la estructura del gasto de la población colombiana. Por tal razón, se crea una nueva metodología para calcular el IPC, con lo cual la canasta de bienes y servicios se actualiza para la inflación, por lo tanto, lo mejor es tomar datos relativamente cercanos al cambio metodológicos para mantener la misma canasta de bienes y servicios permitiendo una estimación más eficiente.

2. Grafique la serie.

La serie se gráfica tanto en niveles como en escala logarítmica. Sin embargo, respecto a la última se demuestra que no hay una ganancia significativa en la explicación debido a que los valores son muy cercanos a cero y pueden producir sesgos en la serie.



Serie Logarítmica de la Inflación mensual



Finalmente, las gráficas muestran que se puede deducir un cierto comportamiento estacional por la repetición presente en los ciclos de la serie.

3. Discuta, a la luz de la teoría económica y financiera, cuáles de los componentes son relevantes para incluir en su modelo.

Para un modelo de pronóstico de la inflación, los componentes relevantes son tanto la tendencia, la estacionalidad y el ciclo. En primer lugar, Michel (2015) muestra que países de pequeña economía abierta tienen una inflación que se ve afectada de manera significativa por la estacionalidad de la economía.

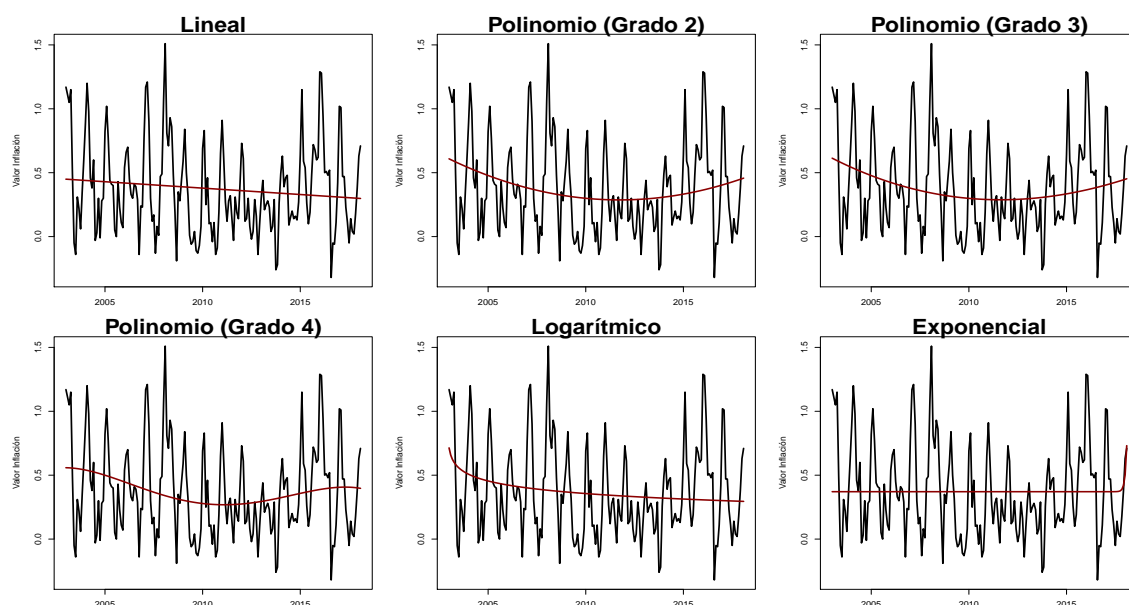
De igual forma, debido al Esquema de Inflación Objetivo que sigue el Banco de la República desde los 2000's, hay una tendencia a disminuir la inflación dentro de los intervalos de confianza de la meta del 3 por ciento que propone el Banco (Banco de la República, 2013). Finalmente, hay una parte que no puede ser explicada ni por la tendencia ni por la estacionalidad y son los choques exógenos del ciclo económico como los fenómenos naturales de El Niño y La Niña, que tuvieron un impacto positivo en el aumento de precios hace dos años. Estos choques sin embargo se toman como aleatorios e impredecibles y por tanto no se pueden incluir en el pronóstico.

Por lo tanto, la inflación está determinada tanto por un componente estacional, explicado porque la inflación depende en alguna medida del crecimiento económico, un componente tendencial y un componente cíclico, dado por los choques exógenos que afectan la economía y tienen un impacto en el nivel de precios.

4. Estime los componentes de tendencia y estacionalidad (si es relevante). Justifique con estadísticas y criterios de información del modelo estimado.

En primer lugar, se estiman las siguientes formas funcionales para la tendencia: lineal, cuadrática, cúbica, grado 4, logarítmica y exponencial. Las cuales muestran el siguiente gráfico:

Ajuste de las formas funcionales de la tendencia



Tendencia: Criterios de información

	Modelo	AIC	BIC	R2_ajustado	Box_Pierce	Ljung_Box	P_valor_f
1	Lineal	149.90	159.52	0.01	0.00	0.00	0.10
2	Polinomio (Grado 2)	144.38	157.19	0.04	0.00	0.00	0.01
3	Polinomio (Grado 3)	146.37	162.39	0.04	0.00	0.00	0.02
4	Polinomio (Grado 4)	147.82	167.04	0.04	0.00	0.00	0.03
5	Logarítmico	144.31	153.92	0.04	0.00	0.00	0.00
6	Exponencial	151.45	161.07	0.00	0.00	0.00	0.29


De lo anterior, tanto de la gráfica como de los criterios de información, se puede concluir que la serie claramente no es ruido blanco por el p-valor arrojado por la *prueba de Ljung-Box*, lo cual muestra que alguno de los supuestos para un buen pronóstico no se está cumpliendo. Esto sugiere que el modelo tiene un componente tendencial o cíclico que aún no se ha incluido. En esa dirección, existen distintos modelos de tendencia que ajustan de manera plausible la serie. En la tabla se muestra que los modelos que mejor ajustan, según los criterios de información AIC y BIC, son las tendencias no lineales de Grado 2 y 4 junto con la logarítmica. Sin embargo, es interesante notar que para el criterio BIC el modelo lineal tiene un mejor ajuste.

En este orden de ideas, dado el criterio de parsimonia sólo se tendrá en cuenta los modelos cuadráticos y de grado 4, porque presentan los mejores criterios de información, junto con la tendencia lineal, esto porque la función logarítmica, aunque tiene un buen ajuste, no es apropiada para la serie porque esta tiene valores muy cercanos a 0 que son sobreestimados por el logaritmo.

Ajuste por Tendencia y Estacionalidad

Dado el análisis expuesto anteriormente, se selecciono un modelo de tendencia de polinomio grado 2 y polinomio grado 4, adicional a ello, se usa uno de tendencia lineal. Al añadir el componente estacional, los mejores modelos ajustan de la siguiente manera:

Mejores modelos de Tendencia y Estacionalidad




Tendencia y Estacionalidad: Criterios de información


	Modelo	AIC	BIC	R2_ajustado	Box_Pierce	Ljung_Box	P_valor_f
1	Lineal	19.07	63.93	0.78	0.00	0.00	0.00
2	Polinomio Grado 2	9.06	57.12	0.79	0.00	0.00	0.00
3	Polinomio Grado 4	7.66	62.13	0.79	0.00	0.00	0.00

En primer lugar, las gráficas evidencian que hay un buen ajuste de los modelos respecto a la serie. Específicamente, la tendencia pareciera aproximar de mejor forma el comportamiento de los datos. Así mismo, se puede ver que la estacionalidad es significativa para los tres casos, con p-valores muy cercanos a cero. De igual forma, es importante notar que los resultados de los tres modelos arrojan p-valores que hacen significantes todas las estaciones, con algunas excepciones del modelo de Grado 4 que presenta una estaciones que no son significativas. Adicional a ello, la tendencia lineal es significativa con un p-valor del 0.0325, la cuadrática con un p-valor de 0.000180 y la de Grado 4 con uno de 0.027.

Finalmente, luego de limpiar por los modelos de tendencia y de estacionalidad, los residuales de los modelos ajustados no son ruido blanco porque tienen p-valores muy cercanos a cero para las **pruebas de Box Pierce y de Ljung-Box**. Lo anterior sugiere la necesidad de un componente cíclico para el pronóstico de los datos.

5. Construya y grafique la serie desestacionalizada y sin tendencia.





Al graficar la serie desestacionalizada y sin tendencia se puede ver que no hay mucha diferencia entre la aproximación de las tres series, excepto pequeños cambios en la escala y en los valores máximos y mínimos para cada una de ellas. Lo que si se puede evidenciar es que las series parecen mostrar que están centradas en cero pero que no siguen mostrando un comportamiento ruido blanco.

6. Estime el componente cíclico (si es relevante). Justifique con estadísticas y criterios de información el modelo estimado.

Prueba: Ljung-Box

	Modelo	Ljung_Box	Box_Pierce
1	Lineal	0.00	0.00
2	Grado 2	0.00	0.00
3	Grado 4	0.00	0.00

Por lo tanto, se puede evidenciar que luego de eliminar tanto la tendencia como la estacionalidad para los tres modelos de tendencia seleccionado, la serie no es ruido blanco. Así pues, se puede concluir que existe un componente cíclico que está influenciado el comportamiento de los errores, por lo cual se debe buscar una aproximación al mismo para lograr un mejor pronóstico.

Siguiendo con lo anterior, al usar la función Autoarima a la serie desestacionalizada y sin tener en cuenta ninguna de las tendencias se puede concluir que el mejor modelo posible bajo los criterios de información AIC y BIC es un **AR(1)**. Lo anterior tiene sentido debido al comportamiento autoregresivo de la inflación, que muestra que los valores del período anterior tienen un poder explicativo significativo sobre los del futuro, esto puede deberse a que las decisiones del Banco de la República, como institución que controla el comportamiento de la inflación en la economía, tienden a mantenerse en una senda de decisión relativamente constante en el tiempo.

Finalmente, se probarán varios modelos modificando los rezagos del AR y del MA para

intentar aproximar el mejor modelo posible analizando tanto los criterios de información como usando el principio de parsimonia. Así mismo, es importante aclarar que no se tendrán en cuenta modelos diferencia, puesto que, no es necesario al controlar por las variables Dummies de estacionalidad y de tendencia.

Modelos usando tendencia lineal

Los resultados de las iteraciones muestran que el mejor modelo para el componente cíclico con una tendencia lineal es un AR(1) y que a medida que se aumentan los p, el criterio BIC tiende a crecer.

Iteración del AR(p)

	Orden	AIC	BIC
1	ARIMA(0,0,0)	19.07	63.93
2	ARIMA(1,0,0)	-53.54	-5.48
3	ARIMA(2,0,0)	-51.78	-0.52
4	ARIMA(3,0,0)	-52.13	2.34
5	ARIMA(4,0,0)	-51.70	5.97
6	ARIMA(5,0,0)	-51.07	9.81

Así mismo, los modelos que agregan un componente de MA(q) con un q distinto a 1 no mejoran el ajuste del modelo según los criterios de información. Por lo tanto, se sigue sosteniendo que el mejor modelo es un AR(1).

Iteración del MA(q)

	Orden	AIC	BIC
1	ARIMA(1,0,0)	-53.54	-5.48
2	ARIMA(1,0,1)	-51.91	-0.64
3	ARIMA(1,0,2)	-52.16	2.31
4	ARIMA(1,0,3)	-51.59	6.08
5	ARIMA(1,0,4)	-50.77	10.11
6	ARIMA(1,0,5)	-50.96	13.12

Modelos con tendencia cuadrática

Los resultados siguen siendo coherentes respecto al modelo de tendencia lineal, es decir, para una tendencia cuadrática el mejor modelo para el ciclo es un AR(1).

Iteración del AR(p)

	Orden	AIC	BIC
1	ARIMA(0,0,0)	9.06	57.12
2	ARIMA(1,0,0)	-54.95	-3.68
3	ARIMA(2,0,0)	-53.52	0.95
4	ARIMA(3,0,0)	-53.26	4.41
5	ARIMA(4,0,0)	-52.49	8.38
6	ARIMA(5,0,0)	-52.29	11.79

Análogamente, la iteración de los modelos que agregan un MA(q) muestran que los criterios de información no mejoran cuando q es distinto a 1.

Iteración del MA(q)

	Orden	AIC	BIC
1	ARIMA(1,0,0)	-54.95	-3.68
2	ARIMA(1,0,1)	-53.75	0.72
3	ARIMA(1,0,2)	-52.86	4.82
4	ARIMA(1,0,3)	-51.86	9.02
5	ARIMA(1,0,4)	-52.95	11.13
6	ARIMA(1,0,5)	-51.32	15.96

Modelos con tendencia de Grado 4

Similar a lo anterior, los resultados también se mantienen para un modelo con tendencia de Grado 4, e incluso, se muestra que para el AR(1) tiene el AIC más pequeño de los tres modelos de tendencia. Sin embargo, es el modelo con menos parsimonia de todos, con lo cual, puede no ser el mejor modelo para el pronóstico.

Iteración para AR(p)

	Orden	AIC	BIC
1	ARIMA(0,0,0)	7.66	62.13
2	ARIMA(1,0,0)	-52.48	5.19
3	ARIMA(2,0,0)	-51.22	9.66
4	ARIMA(3,0,0)	-50.62	13.46
5	ARIMA(4,0,0)	-49.57	17.72
6	ARIMA(5,0,0)	-49.68	20.81

Finalmente, la iteración de los modelos MA(q) sigue sosteniendo lo mismo respecto a que el mejor modelo es un AR(1) y que agregar rezagos MA(1) no mejora la modelación del ciclo.

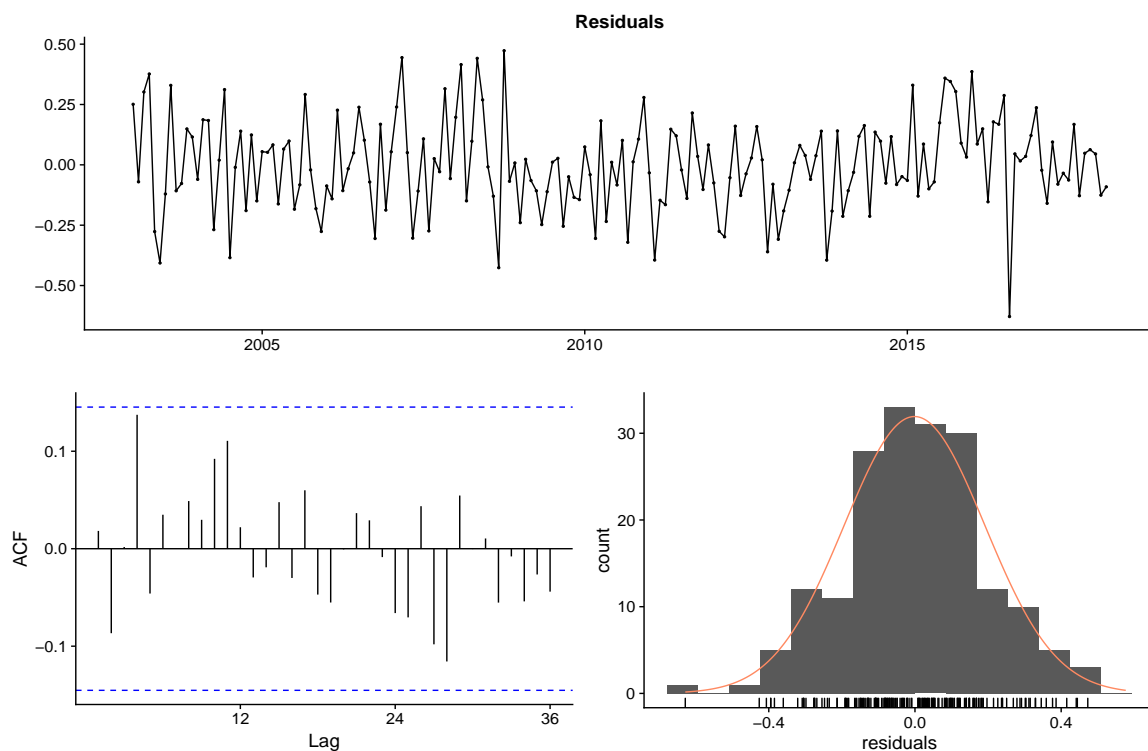
Iteración para MA(q)

	Orden	AIC	BIC
1	ARIMA(1,0,0)	-52.48	5.19
2	ARIMA(1,0,1)	-51.47	9.41
3	ARIMA(1,0,2)	-50.14	13.94
4	ARIMA(1,0,3)	-49.01	18.27
5	ARIMA(1,0,4)	-50.39	20.10
6	ARIMA(1,0,5)	-48.41	25.29

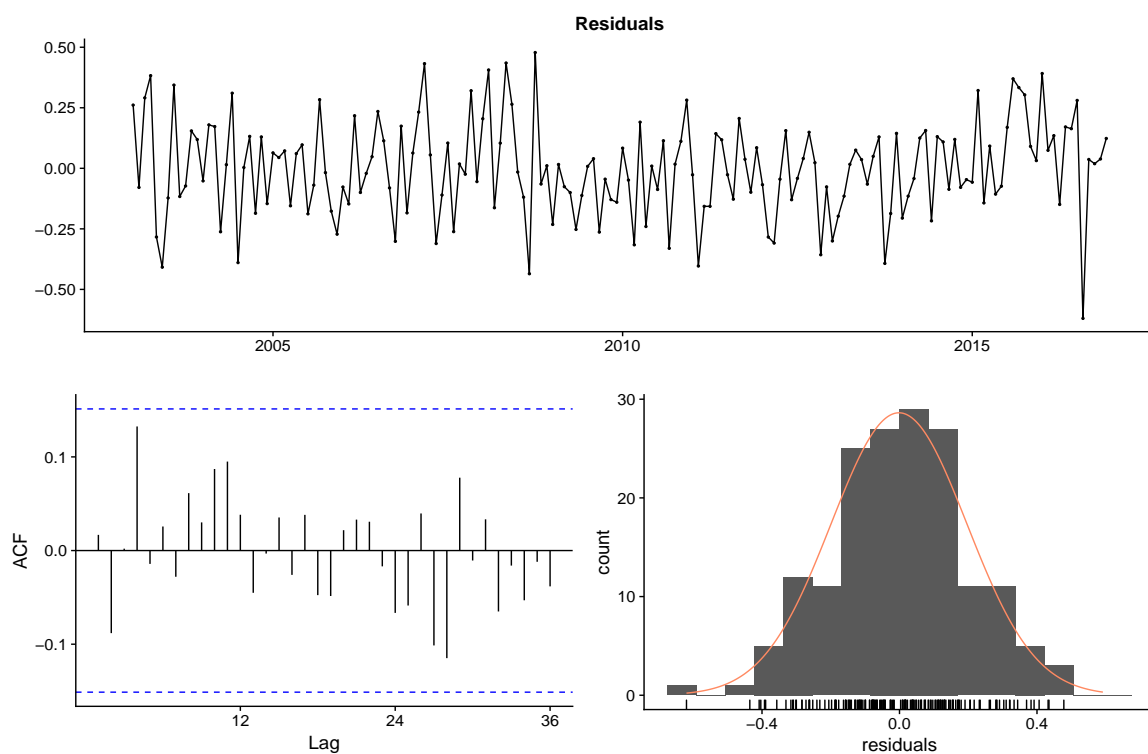
En conclusión, para todos los modelos de tendencia, el mejor modelo para el ciclo es un AR(1).

7. Construya y grafique la serie de residuales. Justifique que se trata de ruido blanco.


Residuales para la Tendencia lineal:



Residuales para la Tendencia Cuadrática:



Residuales para la Tendencia de Grado 4:



Pruebas de Ruido Blanco


	Modelo	Ljung_Box	Box_Pierce
1	Lineal	0.80	0.81
2	Grado 2	0.83	0.83
3	Grado 4	0.66	0.66

En este caso es posible ver que los residuales se comportan como Ruido blanco dado que no se rechaza la hipótesis nula en las pruebas de Ljung Box y Box Pierce. También se ve en las ACF de todos los modelos que ningún rezago resulta significativo por lo que no es posible extraer más información.


8. Estime la dinámica de la varianza (si es relevante).

En este punto, es importante ver si existe una correlación serial en los errores, o si existe clusters de volatilidad de los cuales se pueda extraer información y mejorar el pronóstico. Para esto, estimamos los residuales al cuadrado y analizamos las ACF y la PACF.

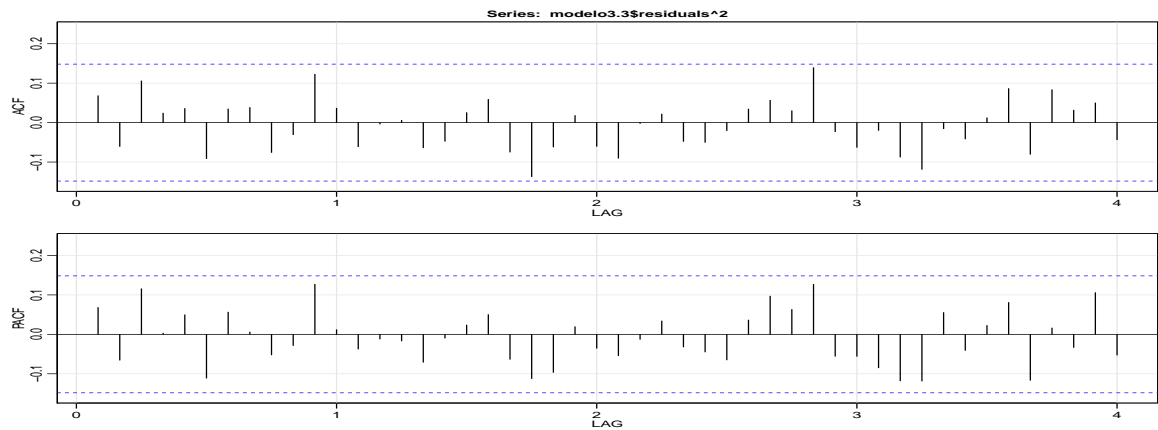
Tendencia Lineal: ACF y PACF (Errores al cuadrado)



Tendencia Cuadrática: ACF y PACF (Errores al cuadrado)



Tendencia de Grado 4: ACF y PACF (Errores al cuadrado)



Como se puede ver en la ACF y la PACF no se evidencia ningún comportamiento de los residuales al cuadrado que pueda estimarse y mejorar el pronóstico inicial. Por esto se descarta la posibilidad de estimar un GARCH.

9. Justifique que su modelo captura todas las dinámicas de varianza relevantes. Realice las pruebas necesarias.

Como se evidenció en el numeral anterior, los modelos propuestos no tienen ninguna dinámica de varianza relevante. Los residuales al cuadrado se encuentran dentro de los intervalos y no resultan significativos para ningún rezago. Dado esto no consideramos pertinente estimar un GARCH y por tanto no vamos a hacer pruebas sobre sus coeficientes.

10. Documente pruebas de normalidad, u otras relevantes para justificar los supuestos de su modelo.

Pruebas de Normalidad para los errores

	Modelo	Media	Desviacion	Curtosis	Skewness	JV_pvalor	L_B
1	Lineal	0.00	0.19	0.07	-0.03	0.95	0.80
2	Grado 2	0.00	0.20	-0.04	-0.05	0.96	0.83
3	Grado 4	0.00	0.19	0.30	-0.00	0.66	0.66


Interperación: Al aplicar las pruebas de normalidad, se puede concluir que los errores siguen una distribución normal debido a que el p-valor de la prueba de Jarque-Bera es mayor a 0.05. Esto permite realizar las simulaciones necesarias para construir el

pronóstico asumiendo una distribución normal sin problemas. Además, la prueba de Ljung-Box también arroja unos p-valores mayores a 0.05 que permiten concluir que los errores son ruido blanco.

Pronóstico dentro de la muestra:

Además de las pruebas ya realizadas, es importante hacer un pronóstico dentro de la muestra para ver el verdadero ajuste del modelo respecto a la tendencia y a la estacionalidad de los datos. Específicamente, la serie se divide en dos submuestras, la primera contiene la inflación desde enero del 2003 hasta febrero del 2017 y la segunda contiene los datos desde marzo del 2017 hasta febrero del 2018. Así pues, se pronostica para 12 pasos adelante, para comparar el pronóstico con los verdaderos datos de la submuestra.

Pronósticos en muestra para los tres modelos de tendencia




Al realizar el pronóstico dentro de la muestra se puede evidenciar que el modelo que mejor se ajusta a los datos de la muestra es el modelo lineal, debido a que los modelos cuadráticos y de Grado 4 tienen una diferencia considerable en la escala aunque sigan la forma funcional del ciclo. Finalmente, siguiendo el principio de parsimonia y dado que el mejor modelo que se ajusta a la muestra es el lineal, será éste el que se tenga en cuenta para realizar el pronóstico de la inflación de marzo del 2018.

11. **Construya el pronóstico puntual, el intervalo de 95 por ciento de confianza y la densidad.**

Volviendo a retomar el ejercicio, vamos a pronosticar la inflación de marzo del 2018. Después de hacer distintas pruebas e iteraciones se encontró que el mejor modelo posible para el pronóstico es uno con tendencia lineal, desestacionalizado y con un proceso AR(1) sobre el ciclo. Así pues, el pronóstico por fuera de la muestra se hace a partir de marzo del 2018 y con un horizonte de 12 pasos adelante. El resultado se muestra a continuación:


Pronósticos fuera de la muestra



Así mismo, se simula la distribución del pronóstico puntual para marzo y se llega a la

siguiente distribución:

Densidad del Pronóstico con Tendencia Lineal de la Inflación



En el gráfico anterior se presenta, el pronóstico puntal para la inflación de marzo del 2018, la densidad y los intervalos de confianza. Como se mostró anteriormente, al cumplirse test de Jarque Bera, se puede asumir que los errores se distribuyen como normales. Dado lo anterior, se planteó 100000 simulaciones de las perturbaciones asumiendo una distribución normal. El punto pronosticado para la inflación es 0.450403553 para marzo del 2018. Los intervalos de confianza para el 95 % es 0.05845969 (2.5 %) y 0.8423474 (97.5 %)

3. Crecimiento del PIB

1. Descargue los datos. Seleccione un periodo de análisis. Justifique el periodo seleccionado


Para pronosticar el crecimiento del PIB por el lado de la oferta para el primer trimestre de 2018, se descargo la serie de tiempo del Producto Interno Bruto Trimestral por Ramas de actividad económica a precios constantes - Series Sin Desestacionalizar - IV trimestre de 2017. Estos datos se descargaron del DANE, y se encuentran disponibles desde 2001 hasta el 2017 con una periodicidad trimestral. Finalmente, esta serie de tiempo cuenta con el PIB por sector, y el agregado de todo los sectores de la oferta, que es la información de nuestro interés.


Dado que es importante poder capturar el ciclo económico se toma la serie lo más larga prosible. Sin embargo no se toman los noventas dada la inestabilidad de la crisis. Esta podría terminar afectando el pronósticos y es un evento atípico. Por este motivo se toma el PIB desde el 2001 hasta el último trimestre del 2017.

Dado que queremos estimar el crecimiento real de la economía es mejor tomar la serie del PIB a precios constantes y no a precios corrientes. Si la tomamos a precios corrientes tendríamos que hacer alguna aproximación sobre cuánto de ese crecimiento del PIB nominal va a deberse al incremento en precios y cuánto al crecimiento real de la economía, lo que podría ir en detrimento de un buen pronóstico.

Otro factor para tomar en cuenta es que la serie no está desestacionalizada. Intencionalmente se escogió de esta manera debido a que la estacionalidad de la serie puede dar información relevante que permita mejorar el pronóstico.

2. Grafique la serie.





3. Discuta, a la luz de la teoría económica y financiera, cuáles de los componentes son relevantes para incluir en su modelo.

La teoría económica propone que el PIB tiene un claro componente tendencial y estacional. En cuanto al primero, el PIB siempre tiene una tendencia creciente debido a las mejoras en la productividad total de los factores, al crecimiento poblacional o a cualquier otra medida que mejore la producción del país. El Banco de La República, de hecho, estimó que el crecimiento potencial de la economía entre 2005 y 2015 fue de 4.5 %, posteriormente para el período comprendido entre 2015 y 2020 la perspectiva de crecimiento pasó a ser de 3 %. A pesar de la disminución se espera que el PIB crezca y, por lo tanto, que la serie tenga una tendencia positiva.

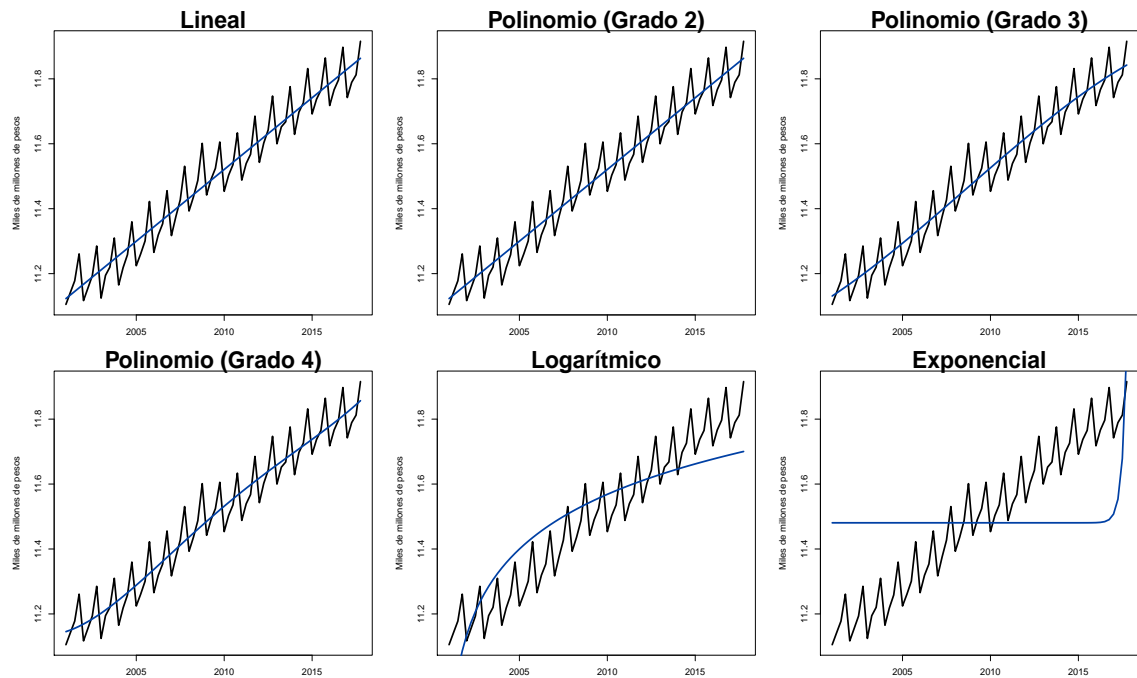
Por otro lado, se tiene un componente estacional debido a las dinámicas que se presentan cada trimestre del año. La dinámica trimestral observada es que el PIB inicia el año con una caída, dado el leve enfriamiento de la economía correspondiente a los ajustes que se dan de un año a otro. Posteriormente, en el segundo trimestre del año se presenta un repunte de la economía, debido a que el ciclo económico se reactiva una vez incorporados los cambios de inicio de año. Por el contrario se presenta de nuevo un leve enfriamiento en el tercer período que se contrapone al repunte del último trimestre, impulsado principalmente por el comercio.

El PIB presenta también un componente cíclico fuerte. Alrededor del crecimiento potencial del que habla el Banco de la República, existen unos trimestres en los que se está por encima o por debajo de este crecimiento debido a choques exógenos imprevistos a la economía e impronosticables.

4. Estime los componentes de tendencia y estacionalidad (si es relevante). Justifique con estadísticas y criterios de información del modelo estimado.

Dado, que la información del crecimiento del PIB elimina información importante de la serie original, de aquí en adelante se va a utilizar la serie del PIB en logaritmos para disminuir su volatilidad y acercar las cifras grandes.

Tendencia: Valores ajustados log PIB




Criterios Tendencia: PIB Trimestral (Oferta)

	Modelo	AIC	BIC	R2_ajustado	Box_Pierce	Ljung_Box	P_valor_f
1	Lineal	-185.81	-179.15	0.93	0.07	0.06	0.00
2	Polinomio (Grado 2)	-183.98	-175.11	0.93	0.06	0.05	0.00
3	Polinomio (Grado 3)	-182.68	-171.58	0.93	0.04	0.04	0.00
4	Polinomio (Grado 4)	-181.29	-167.97	0.93	0.04	0.03	0.00
5	Logarítmico	-100.11	-93.46	0.75	0.00	0.00	0.00
6	Exponencial	-10.81	-4.15	0.08	0.00	0.00	0.01

Tanto en gráfica como en la tabla de los criterios de información, se puede evidenciar que la mejor aproximación a la tendencia es la lineal, la cuadrática y la cúbica. A continuación se presenta estas tres formas funcionales ajustadas por estacionalidad.

Sin embargo, aunque los criterios de información de la formas funcional lineal son los mejores, es importante tener en cuenta que la prueba Box Pierce y Ljung Box indican que al controlar por tendencia esta ya es ruido blanco. Dado lo anterior, vamos a corroborar que sucede en el caso en el que sólo se controle la tendencia y no la estacionalidad. Para eso definimos el Modelo 1, como un modelo que sólo ajusta tendencia de manera lineal, e ignora el comportamiento estacionario de la serie, dado que ya es ruido blanco. Finalmente, agregamos otro modelo, que si controle la estacionalidad por medio de variables Dummies, al cual llamaremos como el modelo 2. A continuación se presentan los criterios de información con los cuáles se seleccionaron las especificidades del modelo 2.

Tendencia: Valores ajustados Log(Colcap)



	Modelo	AIC	BIC	R2_ajustado	Box_Pierce	Ljung_Box	P_valor_f
1	Lineal	-338.06	-324.74	1.00	0.00	0.00	0.00
2	Polinomio (Grado 2)	-337.92	-322.39	1.00	0.00	0.00	0.00
3	Polinomio (Grado 3)	-364.58	-346.83	1.00	0.00	0.00	0.00


Para el caso del logaritmo del PIB, existen diferentes tendencias que ajustan de manera plausible a la serie. Sin embargo, para escoger el mejor modelo de tendencia se tienen que tener en cuenta los criterios de información. En la tabla anterior se puede evidenciar que los mejores modelos según los criterios de información son las tendencias no lineales de Grado 2 y 3, con los mínimos valores para los AIC y BIC, como también con el R cuadrado ajustado más alto. Dado lo anterior, se toma la tendencia lineal, polinomio grado 2 y grado 3. Adicionalmente, se puede evidenciar que la serie es claramente no ruido blanco (prueba de Ljung-Box) lo que es un indicio claro de que se puede mejorar el pronóstico incluyendo más componentes.

Por otro lado, al controlar por estacionalidad, se puede evidenciar que en los tres casos se logra un buen ajuste. Sin embargo, dado los criterios de información, y utilizando el criterio de parsimonia el mejor modelo que ajusta la tendencia y la estacionalidad es el lineal.


Finalmente, a modo de resumen debido a que el modelo lineal sin tendencia parecía ser ruido blanco según la prueba de Ljung-Box al incluir solo tendencia, se hará un primer modelo solo con tendencia lineal (Modelo 1) y otro con tendencia y estacionalidad (Modelo 2) dado lo que la teoría sugiere y que es está muy cercana de la zona de rechazo el estadístico que permitió concluir que ya eran ruido blanco los residuales en el modelo que tiene solo tendencia. El modelo 2 tiene la característica de que se rechaza la hipótesis nula de que los residuales sean ruido blanco. Por este motivo se hará un análisis de ciclo.

5. Construya y gráfique la serie desestacionalizada y sin tendencia.

Modelo 1



Modelo 2



6. Estime el componente cíclico (si es relevante). Justifique con estadísticas y criterios de información el modelo estimado.

Prueba: Ljung-Box

	Modelo	Ljung Box	Box Pierce
1	(Modelo 1)	0.06	0.07
2	(Modelo 2)	0.00	0.00

Utilizando las pruebas Ljung Box y Box Pierce se puede pensar inicialmente que el Modelo 1, es ruido blanco, sin embargo al estar tan cercano a la zona de rechazo, puede llegar a ser problemático. Dado lo anterior, lo mejor es analizar si existe un componente cíclico que esté afectando los residuales. Respecto al modelo 2, este no es ruido blanco, por lo que probablemente existe un componente cíclico que esta influyendo en el comportamiento de los errores. Por lo que se debe buscar una aproximación al ciclo, para lograr eliminar el efecto de este efecto planteamos dos modelos.

Modelo 1

Al ajustar un Autoarima a la serie sin tendencia (líneal) este indica que el mejor modelo posible bajo los criterios AIC y BIC es un ARIMA(4,0,0). Al probar las diferentes iteraciones el mejor modelo posible es ARIMA(4,0,0)

Modelo 2

Al ajustar un Autoarima a la serie ajustada con tendencia lineal y controlando la estacionalidad con variables Dummies este indica que el mejor modelo posible bajo los criterios AIC y BIC es un ARIMA(3,0,1). Vamos a probar modificando los rezagos del AR y del Ma para ver si se puede lograr un mejor modelo analizando los criterios de información y utilizando el principio de parsimonia.

Iteración del AR(P)

	Orden	AIC	BIC
1	ARIMA(0,0,1)	-382.56	-367.03
2	ARIMA(1,0,1)	-429.93	-412.17
3	ARIMA(2,0,1)	-427.80	-407.82
4	ARIMA(3,0,1)	-436.96	-414.77
5	ARIMA(4,0,1)	-435.04	-410.63
6	ARIMA(5,0,1)	-433.89	-407.25

Luego de iterar 5 veces en AR(Q) se puede evidenciar que el mejor modelo de todos bajo el criterio AIC y BIC es un ARIMA (3,0,1)

Iteración del MA(Q) sobre un AR(1)

	Orden	AIC	BIC
1	ARIMA(1,0,0)	-431.68	-416.14
2	ARIMA(1,0,1)	-429.93	-412.17
3	ARIMA(1,0,2)	-430.14	-410.17
4	ARIMA(1,0,3)	-430.80	-408.61
5	ARIMA(1,0,4)	-428.94	-404.52
6	ARIMA(1,0,5)	-427.28	-400.64


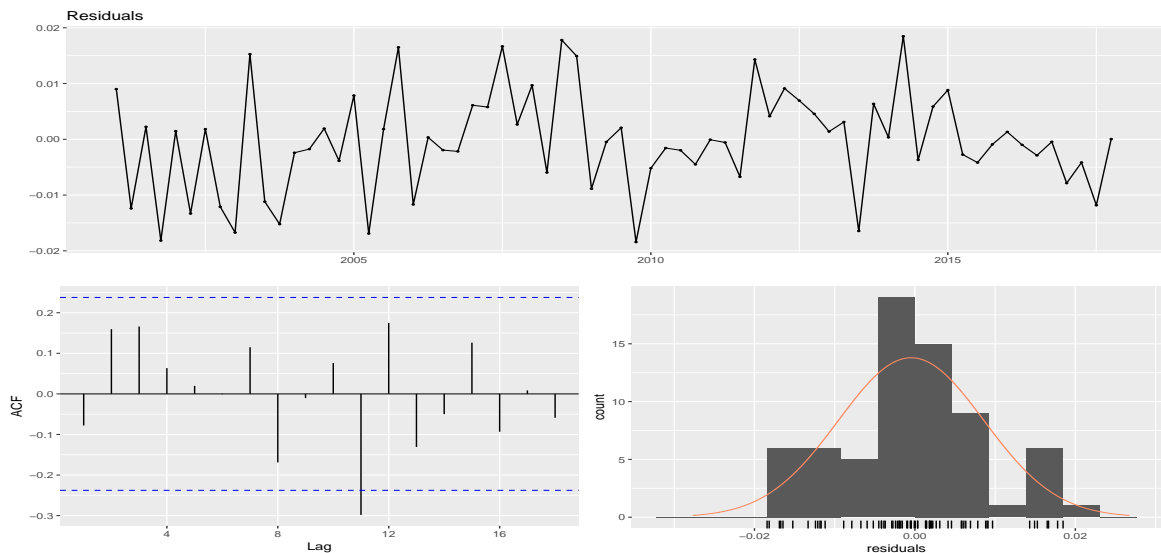
Para probar si el principio de parsimonia aplica en este caso, bajamos el grado sugerido por Autoarima a 1, e iteramos un MA(Q). Luego de iterar 5 veces sobre el MA(Q) se puede evidenciar que el mejor modelo de todos bajo el criterio AIC y BIC es un ARIMA (1,0,0). Dado lo anterior, se puede evidenciar que si bien el ARIMA(3,0,1) alcanza un AIC y un BIC mejor que el ARIMA(1,0,0), este último estima 2 parametros menos, Siguiendo con el criterio de parsimonia, se decide escoger un ARIMA(1,0,0) debido a que los cambios en los criterios de información son relativamente pequeños respecto al número de parámetros que estimar.

Resumen

Modelos	ARIMA	AIC	BIC
Modelo 1	ARIMA(4,0,0)	-329.15	-318.05
Modelo 2	ARIMA(3,0,1)	-436.96	-414.77

7. Construya y grafique la serie de residuales. Justifique que se trata de ruido blanco.

Modelo 1:

**Modelo 2:****Prueba de ruido blanco**

	Modelo	Ljung_Box	Box_Pierce
1	Modelo 1	0.00	0.00
2	Modelo 2	0.51	0.52


Tanto en las gráficas como en la tabla anterior se puede ver que los errores del modelo 1 no son ruido blanco. Lo anterior, sugiere que al utilizar el modelo 1, la prueba de Jarque Bera inicialmente debería validarse con criterio más estricto, en donde este primer modelo no sea ruido blanco. Lo anterior, se genera por que las estaciones del PIB, al quitarse la tendencia generan una especie de ruido blanco, sólo que en este caso son pronosticables. Respecto al segundo modelo, este si se comporta como un Ruido Blanco.

8. Estime la dinámica de la varianza (si es relevante).


En este punto, es importante ver si existe una correlación serial en los errores, o si existe clusters de volatilidad que generen ruido dentro de los modelos estimados anteriormente. Si la varianza de los errores muestra cierto comportamiento se puede mejorar el pronóstico al identificarla. Para esto, estimamos los residuales al cuadrado y analizamos

las ACF y la PACF.

Modelo 1: ACF y PACF (Errores al cuadrado)



Modelo 2: ACF y PACF (Errores al cuadrado)



Las gráficas de ambos modelos permiten ver que no hay comportamientos pronosticables de los residuales al cuadrado por lo que no se puede saber nada de su varianza. Todos los rezagos están dentro de las bandas, ningún rezago resulta significativo. Por este motivo se descarta la posibilidad de realizar un GARCH.

9. **Justifique que su modelo captura todas las dinámicas de varianza relevantes. Realice las pruebas necesarias.**

Como se evidenció en el numeral anterior, los modelos propuestos no tienen ninguna dinámica de varianza relevante. Los residuales al cuadrado se encuentran dentro de los intervalos y no resultan significativos para ningún rezago. Dado esto no consideramos pertinente estimar un GARCH y por tanto no vamos a hacer pruebas sobre sus coeficientes.

10. **Documente pruebas de normalidad, u otras relevantes para justificar los supuestos de su modelo.**

Pruebas


Es posible concluir que el error se comporta normal dado que en la prueba de Jarque Bera

	Modelo	Media	Desviacion	Curtosis	Skewness	JV_pvalor	L_B
1	Modelo 1	0.00	0.02	-0.84	0.00	0.43	0.00
2	Modelo 2	0.00	0.01	-0.38	0.02	0.88	0.51

no es posible rechazar la hipótesis nula. Esto implica que las simulaciones de intervalos de confianza y densidades se pueden realizar tranquilamente bajo este supuesto.


Como en los ejercicios anteriores, se dividió la muestra para revisar cómo era el desempeño de los modelos. El modelo 1 es muy bueno pronosticando dentro de la muestra, sin embargo los errores no son ruido blanco por lo que no es el modelo preferido a pesar del ajuste tan bueno que tiene como se evidencia en la gráfica. Lo anterior, se debe principalmente a que al realizar un pronóstico por fuera de la muestra puede existir factores no observados dentro de los errores que este generando problemas de endogenidad y estén generando un sesgo en el pronóstico por fuera de la muestra. En cuanto al modelo 2, este cumple con todos los supuestos que se quieren de un buen modelo, sin embargo su ajuste dentro de la muestra no es tan bueno. Pero para este de pronóstico preferimos cumplir con el supuesto de que los errores se comportan como ruido blanco y además se distribuyen normalmente, que tener un ajuste perfecto dentro de la muestra. Dado lo anterior, el modelo que se va a utilizar para pronosticar en el siguiente literal es el modelo 2.

Prueba: Pronóstico dentro de la muestra




11. Construya el pronóstico puntual, el intervalo de 95 por ciento de confianza y la densidad.

Pronóstico lineal al logaritmo del PIB




Pronostico lineal del PIB

Dado que el modelo original se realizó una transformación logarítmica, para volver a los niveles del PIB, se realizó una transformación exponencial. A continuación se presentan los resultados.




Densidad



En el gráfico anterior se presenta, el pronóstico puntal para el PIB del primer trimestre del 2018 en Log (Millones de pesos), la densidad y los intervalos de confianza. Como se mostró anteriormente, al cumplirse test de Jarque Bera, se puede asumir que los errores se distribuyen como normales. Dado lo anterior, se planteó 10000 simulaciones de las perturbaciones asumiendo una distribución normal. El punto pronosticado en logaritmo es 11.77093 para el primer trimestre del 2018. Los intervalos de confianza para el 95 % es 11.75268 (2.5 %) y 11.78985 (97.5 %).

Densidad



En el gráfico anterior se presenta, el pronóstico puntal para el PIB del primer trimestre del 2018 en Log (Millones de pesos), la densidad y los intervalos de confianza. Como se mostró anteriormente, al cumplirse test de Jarque Bera, se puede asumir que los errores se distribuyen como normales. Dado lo anterior, se planteó 10000 simulaciones de las perturbaciones asumiendo una distribución normal. El punto pronosticado en niveles es 129434.5 Millones de pesos para el primer trimestre del 2018. Los intervalos de confianza para el 95 % es 129432.5 (2.5 %) y 129436.5 (97.5 %).

Pronostico final

Finalmente, dado que el objetivo de este ejercicio es pronosticar el crecimiento del PIB por el lado de la oferta para el primer trimestre de 2018, teniendo el pronóstico puntal del PIB en niveles del primer trimestre del 2018, únicamente sólo se requiere calcular el crecimiento trimestral del PIB. Específicamente, el PIB en niveles del cuarto trimestre del 2017 fue de 151970 millones, nuestro punto pronosticado fue de 129434.5, al calcular el crecimiento el resultado es -14.8 %. Siendo, este nuestro mejor pronóstico.

4. BONO:Desempleo

Realice el ejercicio anterior para pronosticar el desempleo en febrero de 2018 Construya los pronósticos a la luz del modelo anterior, siguiendo los pasos a continuación.

1. **Descargue los datos. Seleccione un periodo de análisis. Justifique el periodo seleccionado**

Los datos de desempleo se descargaron del DANE y corresponden a la serie mensual que va de enero de 2001 a 2018. Al igual que las demás series es importante tener un periodo amplio de análisis para poder capturar el ciclo económico dado que el desempleo se relaciona con la brecha entre el PIB observado y el potencial (Ley de Okun).


De igual manera es importante que la crisis de finales de los noventas no modifique el pronóstico dado que se considera que esta fue una situación particular que no se quiere que el modelo incluya. Es por esto que se usa la serie desde 2001 y no desde antes. Además de ello, las cifras de desempleo en Colombia a partir de los 2000's, al igual que la inflación, han estado cercanas a un dígito, con lo cual si se toman los datos desde el 2001 se tiene en cuenta de mejor forma el componente autoregresivo del ciclo sobre la serie.

2. **Grafique la serie.**


La serie se grafica tanto en niveles como en escala logarítmica. Sin embargo, la serie en

escala logarítmica no presenta un cambio significativo en la serie más allá de la escala, con lo cual no se tendrá en cuenta en el análisis.

Serie del Desempleo mensual



Serie Logarítmica del Desempleo mensual



Finalmente, las gráficas muestran que se puede deducir un cierto comportamiento estacional por la repetición presente en los ciclos de la serie. Además de ello, también sería esperable una tendencia debido a la relación con la producción, que ya se mostro tendencial, que tiene el desempleo.

3. Discuta, a la luz de la teoría económica y financiera, cuáles de los componentes son relevantes para incluir en su modelo.

El desempleo, según la teoría económica tiende a su valor natural en el tiempo. El desempleo natural es aquel que proviene de la diferencia entre la oferta y la demanda en el mercado laboral por temas estructurales. El gobierno ha hecho esfuerzos positivos para que disminuya el desempleo estructural lo que puede explicar la tendencia decreciente de la serie, sin embargo cada vez es más difícil reducir el desempleo debido a que las políticas necesarias son cada vez más extremas. Esto implica que la tendencia de la serie puede ser decreciente pero no lineal. En este caso se debe tener cuidado porque las tendencias pueden tener buen ajuste para los pronósticos de corto plazo, pero cuando se trata de un plazo más largo debe analizarse muy bien qué se considera que debe ser el pronóstico.

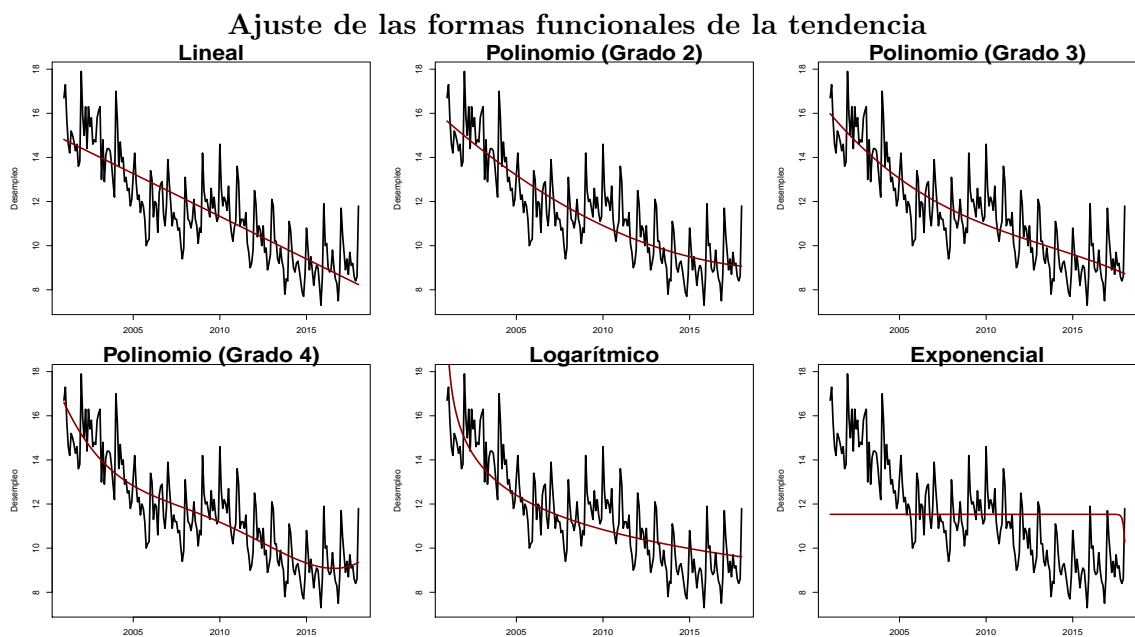
Esta serie también muestra un componente de estacionalidad debido a que como los trabajadores se usan para producir y el producto muestra un comportamiento estacional, la contratación a va ser igual. Es decir, en diciembre y junio cuando la economía es muy productiva el desempleo se reduce, mientras que en enero el desempleo se incrementa

fuertemente.

En cuanto al ciclo, debido a que el desempleo está conectado al producto (Ley de Okun) es inmediato pensar que los ciclos del producto también van a estar presentes en el desempleo. Esto se va a traducir en un componente cíclico en la serie. Por esta razón se espera que la serie cuente con ciclo, tendencia y estacionalidad.

4. **Estime los componentes de tendencia y estacionalidad (si es relevante). Justifique con estadísticas y criterios de información del modelo estimado.**

En primer lugar, se estiman las siguientes formas funcionales para la tendencia: lineal, cuadrática, cúbica, grado 4, logarítmica y exponencial. Las cuales muestran el siguiente gráfico:



Tendencia: Criterios de Información

	Modelo	AIC	BIC	R2_ajustado	Box_Pierce	Ljung_Box	P_valor_f
1	Lineal	671.51	681.47	0.71	0.00	0.00	0.00
2	Polinomio (Grado 2)	652.94	666.23	0.73	0.00	0.00	0.00
3	Polinomio (Grado 3)	652.31	668.92	0.73	0.00	0.00	0.00
4	Polinomio (Grado 4)	646.96	666.90	0.74	0.00	0.00	0.00
5	Logaritmico	693.84	703.81	0.67	0.00	0.00	0.00
6	Exponencial	923.07	933.04	-0.00	0.00	0.00	0.56


De lo anterior, tanto de la gráfica como de los criterios de información, se puede concluir que la serie claramente no es ruido blanco por el p-valor arrojado por la *prueba de Ljung-Box*, lo cual muestra que alguno de los supuestos para un buen pronóstico no se está cumpliendo. Es de esperar que la serie tenga un comportamiento cíclico o estacional que aún no se ha capturado. En este caso, existen distintos modelos de tendencia que ajustan de manera plausible la serie. En la tabla se muestra que los modelos que mejor ajustan, según los criterios de información AIC y BIC, son las tendencias no lineales de Grado 2 y 3 junto con la lineal. La lineal se incluye por parsimonia, la de grado dos porque mejoran los criterios

y la tercera porque al incluir estacionalidad es la que tiene el mejor ajuste. De igual forma, no se incluye la de Grado 4 porque al incluir estacionalidad los criterios de información aumentan.

Ajuste por Tendencia y Estacionalidad

Dado el análisis expuesto anteriormente, se selecciono un modelo de tendencia de polinomio grado 2 y polinomio grado 3, adicional a ello, se usa uno de tendencia lineal. Al añadir el componente estacional, los mejores modelos ajustan de la siguiente manera:

Mejores modelos de Tendencia y Estacionalidad




Tendencia y Estacionalidad: Criterios de información

	Modelo	AIC	BIC	R2_ajustado	Box_Pierce	Ljung_Box	P_valor_f
1	Lineal	540.40	586.93	0.99	0.00	0.00	0.00
2	Cuadrático	502.61	552.46	1.00	0.00	0.00	0.00
3	Cúbico	501.46	554.63	1.00	0.00	0.00	0.00

En primer lugar, las gráficas evidencian que hay un buen ajuste de los modelos respecto a la serie. Específicamente, la tendencia cúbica pareciera aproximar de mejor forma el comportamiento de los datos. Así mismo, se puede ver que la estacionalidad es significativa para los tres casos, con p-valores de cero.

Finalmente, luego de limpiar por los modelos de tendencia y de estacionalidad, los residuales de los modelos ajustados no son ruido blanco porque tienen p-valores de cero para las **pruebas de Box Pierce y de Ljung-Box**. Lo anterior sugiere la necesidad de un componente ciclo para el pronóstico de los datos.

5. Construya y grafique la serie desestacionalizada y sin tendencia.



Al graficar la serie desestacionalizada y sin tendencia se puede ver que no hay mucha diferencia entre la aproximación de las tres series, excepto pequeños cambios en la escala y en los valores máximos y mínimos para cada una de ellas. Además de ello, las gráficas de Grado 2 y 3 tienden a tener un ciclo mayor que la lineal. Lo que si se puede evidenciar es que las series parecen mostrar que están centradas en cero pero que no siguen mostrando un comportamiento ruido blanco.

6. Estime el componente cíclico (si es relevante). Justifique con estadísticas y criterios de información el modelo estimado.

Prueba: Ljung-Box

	Modelo	Ljung_Box	Box_Pierce
1	Lineal	0.00	0.00
2	Cuadrática	0.00	0.00
3	Grado 3	0.00	0.00

Por lo tanto, se puede evidenciar que luego de eliminar tanto la tendencia como la

estacionalidad para los tres modelos, la serie no es ruido blanco. Así pues, se puede concluir que existe un componente cíclico que está influenciado el comportamiento de los errores, por lo cual se debe buscar una aproximación al mismo para lograr un mejor pronóstico.

Siguiendo con lo anterior, al usar la función Autoarima a la serie desestacionalizada y sin tener en cuenta ninguna de las tendencias se puede concluir que el mejor modelo posible bajo los criterios de información AIC y BIC es un **ARMA(2,2)**. Lo anterior tiene sentido debido al comportamiento particular del desempleo que combina tanto comportamiento autoregresivo como de media móvil.

Finalmente, se probarán varios modelos modificando los rezagos del AR y del MA para intentar aproximar el mejor modelo posible analizando tanto los criterios de información como usando el principio de parsimonia. Así mismo, es importante aclarar que no se tendrán en cuenta modelos diferencia, puesto que, no es necesario al controlar por las variables Dummies de estacionalidad y de tendencia.

Modelos usando tendencia lineal

Los resultados de las iteraciones muestran que el mejor modelo para el componente cíclico con una tendencia lineal es un ARMA(2,2) y que a medida que se aumentan los p, el criterio AIC tiende a crecer.

Iteración del AR(p)

	Orden	AIC	BIC
1	ARIMA(0,0,2)	444.04	497.21
2	ARIMA(1,0,2)	372.78	429.27
3	ARIMA(2,0,2)	369.84	429.65
4	ARIMA(3,0,2)	370.55	433.69
5	ARIMA(4,0,2)	372.20	438.66
6	ARIMA(5,0,2)	373.99	443.77

Así mismo, los modelos que agregan un componente de MA(q) con un q distinto a 2 no mejoran el ajuste del modelo según los criterios de información. Por lo tanto, se sigue sosteniendo que el mejor modelo es un ARMA(2,2).

Iteración del MA(q)

	Orden	AIC	BIC
1	ARIMA(2,0,0)	380.21	433.38
2	ARIMA(2,0,1)	372.37	428.86
3	ARIMA(2,0,2)	369.84	429.65
4	ARIMA(2,0,3)	370.32	433.46
5	ARIMA(2,0,4)	371.78	438.24
6	ARIMA(2,0,5)	373.24	443.02

Modelos con tendencia cuadrática

Los resultados siguen siendo coherentes respecto al modelo de tendencia lineal, es decir, para una tendencia cuadrática el mejor modelo para el ciclo es un ARMA(2,2).

Iteración del AR(p)

Análogamente, la iteración de los modelos que agregan un MA(q) muestran que los criterios de información no mejoran cuando q es distinto a 2. Sin embargo, para este caso los criterios son muy cercanos entre sí.

	Orden	AIC	BIC
1	ARIMA(0,0,2)	426.15	482.64
2	ARIMA(1,0,2)	371.11	430.92
3	ARIMA(2,0,2)	368.35	431.48
4	ARIMA(3,0,2)	368.97	435.43
5	ARIMA(4,0,2)	370.56	440.34
6	ARIMA(5,0,2)	372.35	445.46

Iteración del MA(q)

	Orden	AIC	BIC
1	ARIMA(2,0,0)	377.43	433.92
2	ARIMA(2,0,1)	370.75	430.57
3	ARIMA(2,0,2)	368.35	431.48
4	ARIMA(2,0,3)	368.70	435.16
5	ARIMA(2,0,4)	370.06	439.85
6	ARIMA(2,0,5)	371.45	444.55

Modelos con tendencia de Cúbica

Similar a lo anterior, los resultados también se mantienen para un modelo con tendencia cúbica, e incluso, se muestra que para el ARMA(2,2) tiene el AIC más pequeño de los tres modelos de tendencia. Sin embargo, es el modelo con menos parsimonia de todos, con lo cual, puede no ser el mejor modelo para el pronóstico.

Iteración para AR(p)

	Orden	AIC	BIC
1	ARIMA(0,0,2)	427.14	486.95
2	ARIMA(1,0,2)	373.06	436.20
3	ARIMA(2,0,2)	370.23	436.69
4	ARIMA(3,0,2)	370.90	440.68
5	ARIMA(4,0,2)	372.50	445.61
6	ARIMA(5,0,2)	374.29	450.72

Finalmente, la iteración de los modelos MA(q) sigue sosteniendo lo mismo respecto a que el mejor modelo es un ARMA(2,2) y que agregar rezagos de media móvil no mejora la modelación del ciclo.


Iteración para MA(q)

En conclusión, para todos los modelos de tendencia, el mejor modelo para el ciclo es un AR(1).


7. Construya y grafique la serie de residuales. Justifique que se trata de ruido blanco.

Residuales para la Tendencia lineal:


	Orden	AIC	BIC
1	ARIMA(2,0,0)	379.42	439.23
2	ARIMA(2,0,1)	372.69	435.82
3	ARIMA(2,0,2)	370.23	436.69
4	ARIMA(2,0,3)	370.64	440.42
5	ARIMA(2,0,4)	372.03	445.14
6	ARIMA(2,0,5)	373.42	449.85



Residuales para la Tendencia Cuadrática:



Residuales para la Tendencia Cúbica:



Pruebas de Ruido Blanco

Igualmente, es posible ver que los residuales se comportan como Ruido blanco dado que no se rechaza la hipótesis nula en las pruebas de Ljung Box y Box Pierce. También se ve


	Modelo	Ljung_Box	Box_Pierce
1	Lineal	0.60	0.60
2	Grado 2	0.53	0.53
3	Grado 4	0.54	0.55

en las ACF de todos los modelos que sólo un rezago en cada una de ellas es significativo, es posible que la dinámica de los errores tenga clusters y ésta no sea homoscedástica. Por tal razón, en el pronóstico final se tendrá en cuenta un modelo GARCH.


8. Estime la dinámica de la varianza (si es relevante).

En este punto, es importante ver si existe una correlación serial en los errores, o si existe clusters de volatilidad de los cuales se pueda extraer información y mejorar el pronóstico. Para esto, estimamos los residuales al cuadrado y analizamos las ACF y la PACF.


Tendencia Lineal: ACF y PACF (Errores al cuadrado)



Tendencia Cuadrática: ACF y PACF (Errores al cuadrado)



Tendencia de Grado 3: ACF y PACF (Errores al cuadrado)



Como se puede ver en la ACF y la PACF se evidencia que los residuales al cuadrado son significativos para algunos rezagos y que por tal razón se pueda mejorar el modelo respecto a la varianza. Esto confirma la intuición del punto anterior de que un modelo GARCH puede mejorar el pronóstico al capturar mejor la dinámica de la varianza de la serie.

9. **Justifique que su modelo captura todas las dinámicas de varianza relevantes. Realice las pruebas necesarias.**

Como se evidenció en el numeral anterior, los modelos propuestos no tienen ninguna dinámica de varianza relevante. Los residuales al cuadrado se encuentran dentro de los intervalos y no resultan significativos para ningún rezago. Dado esto no consideramos pertinente estimar un GARCH y por tanto no vamos a hacer pruebas sobre sus coeficientes.

10. **Documente pruebas de normalidad, u otras relevantes para justificar los supuestos de su modelo.**

Pruebas de Normalidad para los errores


	Modelo	Media	Desviacion	Curtosis	Skewness	JV_pvalor	L_B
1	Lineal	-0.01	0.55	0.80	-0.20	0.02	0.60
2	Cuadrática	0.00	0.54	0.67	-0.14	0.08	0.53
3	Cúbica	0.00	0.54	0.70	-0.17	0.06	0.54

Interperación: Al aplicar las pruebas de normalidad, se puede concluir que sólo la tendencia cuadrática y la cúbica siguen una distribución normal porque su p-valor es mayor a 0.05. Sin embargo, la tendencia lineal según el test de Jarque-Bera no se comporta como una distribución normal. Además de ello, la prueba de Ljung-Box también arroja unos p-valores mayores a 0.05 que permiten concluir que los errores son ruido blanco.

Pronóstico dentro de la muestra:

Además de las pruebas ya realizadas, es importante hacer un pronóstico dentro de la muestra para ver el verdadero ajuste del modelo respecto a la tendencia y a la estacionalidad de los datos. Específicamente, la serie se divide en dos submuestras, la primera contiene el desempleo desde enero del 2001 hasta diciembre del 2017 y la segunda contiene los datos desde enero del 2017 hasta enero del 2018. Así pues, se pronostica para 12 pasos adelante, para comparar el pronóstico con los verdaderos datos de la submuestra.

Pronósticos en muestra para los tres modelos de tendencia




Al realizar el pronóstico dentro de la muestra se puede evidenciar que el modelo que mejor se ajusta a los datos de la muestra es el modelo lineal, debido a que los modelos cuadráticos y cúbicos tienen una diferencia considerable en la escala aunque sigan la forma funcional del ciclo. Finalmente, siguiendo el principio de parsimonia y dado que el mejor modelo que se ajusta a la muestra es el lineal, será éste el que se tenga en cuenta para realizar el pronóstico del desempleo para febrero del 2018.

11. **Construya el pronóstico puntual, el intervalo de 95 por ciento de confianza y la densidad.**


Volviendo a retomar el ejercicio, vamos a pronosticar la inflación de marzo del 2018. Después de hacer distintas pruebas e iteraciones se encontró que el mejor modelo posible para el pronóstico es uno con tendencia lineal, desestacionalizado y con un proceso ARMA(2,2) sobre el ciclo. Así pues, el pronóstico por fuera de la muestra se hace a partir de febrero del 2018 y con un horizonte de 12 pasos adelante. El resultado se muestra a continuación:

Pronósticos fuera de la muestra



Así mismo, se simula la distribución del pronóstico puntual para febrero y se llega a la siguiente distribución:


Densidad del Pronóstico con Tendencia Lineal de la Inflación



En el gráfico anterior se presenta, el pronóstico puntal para el desempleo de febrero del 2018, la densidad y los intervalos de confianza. Como se mostró anteriormente, al cumplirse test de Jarque Bera, se puede asumir que los errores se distribuyen como normales. Dado lo anterior, se planteó 100000 simulaciones de las perturbaciones asumiendo una distribución normal. El punto pronosticado para el desempleo es 10.545953 para febrero del 2018. Los intervalos de confianza para el 95 % es 9.342187 (2.5 %) y 11.659709 (97.5 %)


Finalmente, se usa un modelo GARCH(1,1), teniendo y aprovechando el acuerdo que existe en la literatura académica sobre el buen ajuste que logran este tipo de modelos, para modelar mejor la varianza del modelo. Dando como resultado la siguiente gráfica del pronóstico para 12 periodos adelante:

Pronósticos con un modelo GARCH(1,1)



Así mismo, el gráfico de la varianza para el modelo muestra que ésta se comporta más estable permitiendo mejorar el pronóstico.

Pronósticos de la varianza incondicional con un GARCH



Así pues, para un modelo GARCH(1,1) el pronóstico de desempleo para febrero es de 10.596, que es muy cercano al predicho anteriormente pero con mayor tamaño. Ahora bien, de acuerdo al comportamiento del desempleo éste pareciera ser un pronóstico acertado y esperable del desempleo para un mes como febrero.